

配水管网压力推定中机器学习模型适用领域(Applicability Domain)深入研读与工程全解

原著作者:山原 裕之, 横山 雄, 金谷 道昭(东芝基础设施系统株式会社 / Toshiba)

一、导读与研究核心执行摘要

在社会基础设施(如城市供水管网)中引入 AI/机器学习技术时, 安全性与确定性远远优于单纯追求高平均精度。机器学习模型作为“黑盒”, 在面对从未见过的输入数据特征时, 预测误差可能发生非线性的剧烈增长。

如果供水运维人员依据失真(高估)的压力预测值去调低配水泵或控制阀, 极易造成局部高地或远端居民区断水事故。东芝团队在这篇论文中, 针对这一工业痛点, 首次全面评估了 5 种机器学习模型适用领域(Applicability Domain, AD)构建方法。其核心逻辑是: 在模型出厂时为其划定“安全信任边界”, 当运行数据走出边界时及时报警, 提示人工干预, 从而阻断重大事故风险。

二、工业痛点与系统架构背景解析

2.1 城市配水系统中的“余量压力”优化困境

为了保障整个配水管网中海拔最高或距离净化水场最远节点(称为末端节点/末端压力点)的正常供水, 水厂通常需要维持较高的整体配水压力。然而:

- 水压过高: 会导致管道漏水量剧增、管网爆裂风险上升, 且配水泵耗电量极大。
- 水压过低: 会直接导致末端用户无水可用, 引发社会事故。

余量压力(Excess Pressure)公式:

余量压力(t) = 实际末端压力(t) - 目标最低维持水压

供水优化的目标是利用泵站与控制阀的动态调节, 使多余的余量压力尽可能趋近于 0, 从而达到节能减排与降低漏损的目的。

2.2 物理传感器监测的现实瓶颈与临时 Logger 解决方案

若要精确掌握末端水压, 最直接的方法是安装在线压力传感器。但在实际管网中, 末端节点往往位于路口下、住宅区边缘等无电源供应、通信信号差的区域, 长期铺设电缆与通信设备的成本极高。

作者提出了极具工程可行性的替代方案:

1. 在目标末端节点仅临时安放电池供电的水压数据记录仪(Water Pressure Data Logger), 连续采集若干天(如 14天~182天)的压力数据。
2. 采集完成后撤走 Logger, 将这期间采集的末端压力作为目标标签(y), 与配水场、调节阀处的在线测量数据(x)联合训练机器学习模型。
3. 在日常运维中, 直接用配水场处的在线数据输入模型, 实时估计末端压力。

2.3 适用领域(AD, Applicability Domain)的概念引入

由于 Logger 撤走后无法实时获得真值校验, 模型便成为了“单向预测器”。当遇到特殊天气、节假日突发用水高峰、管道切调等情况时, 输入特征会脱离训练集的覆盖范围。AD 的本质, 就是在特

征空间中绘制一条边界线:界内数据允许自动化调压;界外数据强制警报并暂停调压,以防范断水风险。

三、物理管网模型与机器学习数学表达

3.1 A 市实际配水管网物理拓扑

论文以日本 A 市的实际配水系统为研究对象, 系统由以下要素构成:

- 配水区: 包含 B1 区和 B2 区两个核心配水区域。
- 配水场: 包含 D1, D2(服务 B1 区)和 D3(服务 B2 区)共 3 个水厂泵站。
- 联络调节阀: 包含跨区阀门 V(连接 B1 和 B2)与跨界阀门 W(与邻近外区连接, 水流可双向流动)。
- 预测目标节点: 位于管网末端的 8 个关键代表点 $n \in \{a, b, c, d, e, f, g, h\}$ 。

3.2 压力推定模型数学方程

对于任意末端节点 n 在时刻 t 的推定压力 $y_{t,n}$, 其机器学习估计模型表达为:

$y_{t,n} = f(t, p, q, j, k, l)$

解释变量(输入特征向量)维度全解:

- **t**: 时刻(考虑一天 24 小时及不同日期的周期性用水模式)。
- **p**: 3 个配水场的实时出口压力集合 $p = \{p_{D1}, p_{D2}, p_{D3}\}$ 。
- **q**: 3 个配水场的实时出口流量集合 $q = \{q_{D1}, q_{D2}, q_{D3}\}$ 。
- **j**: 联络调节阀的阀门开度集合 $j = \{j_v, j_w\}$ 。
- **k**: 联络调节阀处的实时流量集合 $k = \{k_v, k_w\}$ 。
- **l**: 联络调节阀处的实时压力集合 $l = \{l_v\}$ 。

3.3 预测误差的工程定义与非对称危害

时刻 t 的估计误差定义为: $err_t = D_{est,t} - D_{act,t}$ (其中 $D_{est,t}$ 为模型预测水压, $D_{act,t}$ 为真实水压)。

⚠ 误差方向的工程危害非对称性:

- 正误差 ($err_t > 0$, 即高估水压): 运维人员误以为末端水压很充足, 进而大幅降低配水场泵压, 导致末端居民区实际水压过低甚至断水(极度危险!)。
- 负误差 ($err_t < 0$, 即低估水压): 误以为末端水压不足而提高泵压, 仅造成短暂的能源浪费, 不会导致安全事故。

四、5 种 Applicable Domain (AD) 决定算法深度剖析

针对多维特征空间, 论文对比了 3 种思想体系下衍生出的 5 种具体 AD 构建算法:

分类体系	算法名称	缩写	空间判定几何形状	数学判定条件 / 逻辑说明	优点与局限性分析
基于边界范围	特征最大最小值范围法	minMax	超矩形包络 (Hyper-rectangle)	输入的每一个特征值必须均满足: $Min(x_{i,train}) \leq x_{i,input} \leq Max(x_{i,train})$	优点: 计算速度快、直观。 局限: 视各变量完全独立, 无法捕捉变量间的联动关系, 极易

分类体系	算法名称	缩写	空间判定几何形状	数学判定条件 / 逻辑说明	优点与局限性分析
					造成误报警。
基于均值距离	均值中心欧氏距离法	tCD_Euc	超球体包络 (Hyper-sphere)	计算输入点与训练集中心均值 $\bar{x}$ 的欧氏距离： $d = x_{input} - \bar{x} _2$	优点：综合考虑所有特征。 局限：假设特征空间各向同性，未考虑量纲差异与相关性。
	均值中心马氏距离法	tCD_Mah	超椭球体包络 (Hyper-ellipsoid)	引入协方差矩阵 Σ 计算马氏距离： $D_M = \sqrt{((x_{input} - \bar{x})^T \Sigma^{-1} (x_{input} - \bar{x}))}$	优点：消除了量纲影响，严格捕捉了流量与水压之间的高度强相关性。 局限：假设数据呈单峰正态分布。
基于数据密度	k近邻欧氏距离密度法	kNN_Euc	多孔复杂多边形包络	计算输入点到训练集最近 k 个点的平均欧氏距离： $\bar{d}_{kNN} = (1/k) \sum d(x_{input}, x_{neighbor\ i})$	优点：能精准适应非均匀分布、存在多簇集聚的数据集。 局限：计算复杂度较高。
	k近邻马氏距离密度法	kNN_Mah	局部自适应椭球包络	利用马氏距离矩阵计算输入点到近邻 k 个点的平均马氏距离，阈值取训练集内最大平均马氏距离。	优点：兼具局部密度自适应性与特征相关性捕捉能力，理论上最为完备。

💡 为什么马氏距离(Mahalanobis Distance)对水务管网至关重要？
在供水管网中，配水场流量 q 与配水压力 p 之间遵循水力学物理规律(水阻与管道压降正相关)，数据点集中在一条斜向狭长的带状区域内。

- 欧氏距离(圆形边界)：会将许多“压力小但流量大”(远离斜对角线、物理上异常)的数据误判为 AD 内；同时把带状区域两端正常的极端高峰数据误判为 AD 外。
- 马氏距离(椭圆边界)：旋转并拉伸坐标轴，完全契合物理变量的相关性方向，判定极其精准。

五、仿真实验与多维度评估体系

5.1 数据集与仿真参数设置

- 数据来源：日本 A 市长达 1 整年(365 天 / 8,760 小时) 的真实监测数据。
- 训练数据天数 N 梯度：设置 $N \in \{14\text{日}, 28\text{日}, 91\text{日}, 182\text{日}\}$ (分别对应 2周、1个月、1季度、半年)，用于评估“数据采集时长对模型可靠性的影响”。
- 实验规模：8 个预测节点 × 12 个训练起始月份 × 4 种训练天数 × 5 种 AD 算法 = **1,920 组** 综合仿真实验。

5.2 三大核心评估维度

- 1. 维度一:AD 外判定比例(Out-of-AD Ratio)—— 衡量模型在日常运行中“报出警报的频繁程度”。警报率过高(如 20% 的时间都在报错)会导致系统无法正常运行自动优化。
- 2. 维度二:AD 内外的预测误差区分能力 —— 评估 AD 算法是否真正挑选出了大误差数据。合格的 AD 算法必须满足:AD 内样本的预测误差(平均绝对误差、最大绝对误差)显著小于 AD 外样本。
- 3. 维度三:假定真值下的分类性能指标(F-score & Recall)—— 设定安全误差阈值(|err| > 0.022 MPa)为“真 AD 外”, 计算 Recall(查全率/召回率 - 拦截高风险大误差样本的比例)与 Precision(查准率)。

六、实验结果全面对比与深度研析

6.1 AD 外判定比例对比

- 训练天数 N 的决定性影响: 当训练天数增加到 91 天或 182 天时, 绝大多数算法的 AD 外判定比例均下降到 1% 以下。这表明 3~6 个月的数据积累已能覆盖全年中绝大部分常规用水场景。
- minMax 算法的缺陷: 在仅有 14 天训练数据时, minMax 的 AD 外判定比例高达 **17.79%** (而 kNN_Mah 仅为 2.41%), 因为只要 12 个特征中有一个稍微超过历史极值就被剔除, 造成严重误报。

6.2 预测误差区分度对比

AD 算法	平均绝对误差 满足「AD内 < AD 外」的比例	最大绝对误差 满足「AD内 < AD 外」的比例	最大正误差 满足「AD内 < AD 外」的比例	综合评价
minMax	82.0% ~ 98.9%	11.6% ~ 37.3%	1.7% ~ 5.9%	差 无法识别最大误差与破坏性高估误差。
tCD_Euc	94.3% ~ 99.5%	0.0% ~ 10.9%	0.0% ~ 5.8%	中等 仅对平均误差敏感。
tCD_Mah	87.0% ~ 99.3%	1.0% ~ 23.8%	1.9% ~ 4.3%	中等 椭圆边界过宽, 漏掉部分边缘大误差。
kNN_Euc	94.3% ~ 99.5%	1.5% ~ 11.9%	2.5% ~ 10.1%	良好 密度判定有效, 但受欧氏距离限制。
kNN_Mah	93.4% ~ 95.8%	2.4% ~ 20.4%	3.7% ~ 7.0%	最优 在不同训练天数下表现最稳定, 能可靠区分极端误差。

6.3 假定真值分类精度与工程安全评估

- 召回率(Recall - 供水安全命脉): 在所有 5 种算法中, 采用马氏距离的 **tCD_Mah** 与 **kNN_Mah** 召回率最高(在 14 天训练集下, tCD_Mah 召回率达 23.8%, kNN_Mah 达

20.4%)。这意味着它们能够成功拦截绝大多数隐藏的高风险预测。

- **F 值(F-score - 综合平衡)**: 在 91 天 / 182 天长周期训练下, **kNN_Mah** F 值最高, 达到了最佳的平衡。

七、论文最终结论与落地指南

7.1 综合评估结论

最终推荐: 综合各指标, 基于马氏距离的 **k** 近邻数据密度法(**kNN_Mah**)是配水管网压力估计机器学习模型的最佳 **AD** 决定方案。

7.2 供水工程落地实施指南

1. 前期 **Logger** 部署时长建议: 强烈建议在目标节点放置水压数据记录仪的采集时长不得少于 **91 天(3 个月)**。短于 1 个月的训练集无法提供足够的特征多样性, 会导致 **AD** 边界过窄。
2. 控制系统逻辑集成:
 - 当输入特征落在 **kNN_Mah** 决定域内: 触发自动化配水优化逻辑, 自动微调配水泵与调节阀, 切除“余量压力”, 实现节能降耗。
 - 当输入特征走出 **AD** 域: 系统弹出红字警告, 提示“当前管网工况脱离 AI 经验库”, 联动控制系统保持当前压力或恢复默认安全压力, 强制人工接管。