

AIモデル運用時の学習外入力データ検知手法

最終スライドに対応した日本語発表原稿

発表時間の目安は28分10秒です。30分まで約1分50秒の余裕を設けています。時間には、図を指す動作、短い間、ページ送りを含みます。実際の所要時間は、一度通して読み、調整してください。

本文は最終PDFの31ページに対応しています。見出しにはPDFの通し番号と、スライドに印刷されたページ番号を併記しています。スライド22はPDFに存在しないため、番号を補っていません。

灰色の時間表示と青緑色の指図メモは読み上げません。付録Aは質疑用です。通常はまとめの後、付録を飛ばして謝辞へ進んでください。末尾の準備メモも発表本文には含めません。

写真に書かれた説明・転換のメモは、該当する本文に織り込んでいます。二つのモデルが例であること、各異常の具体的な意味、代表的な結果図、適用条件から評価へのつながりを明示しました。

時間の確認地点

PDF 08 調査した論文 5:05

PDF 17 検知手法の分類 14:40

PDF 22 OutProの評価結果と制約 21:20

PDF 26 評価データと評価指標 25:40

PDF 29 まとめと今後の課題 27:55

PDF 31 謝辞 28:10

表紙

0:00-0:20 | 20 秒

早稲田大学大学院情報生産システム研究科の梁希晨です。本日は、実習で調査した、AIモデル運用時の学習外入力データ検知手法について報告します。多変量の数値を入力とする回帰モデルへの適用を中心に説明します。

PDF 02 | スライド 00

目次

0:20-0:40 | 20 秒

発表は六つの部分です。まず背景と対象を説明し、読んだ文献を紹介します。次に、学習外入力の定義と分類を整理します。その後、AEとOutProの仕組みと評価結果を説明し、今回のモデルへの適用条件と今後の課題をまとめます。

PDF 03 | スライド 01

背景と調査対象

0:40-0:45 | 5 秒

まず、調査の背景と対象から説明します。

PDF 04 | スライド 02

背景と調査目的

0:45-2:00 | 75 秒

指図メモ 上段の学習、下段の予測、赤い検知経路の順に指す。

社会インフラでは、センサーから得られるデータを用いて、設備の状態や将来の値を推定するAIモデルの利用が考えられています。ここでは、AIの出力の一例として予測値を使って説明します。

図の上半分が学習です。過去の入力と正解に相当する値を使い、パラメータを繰り返し更新します。下半分では、その学習済みパラメータを固定して、新しい入力から出力を求めます。

ところが、実運用では、運転条件の変更や未知の環境、センサーの変化などにより、学習時に十分含まれていなかった入力がある可能性があります。そのとき、モデルが値を出せても、予測の信頼性が下がるおそれがあります。

そこで、下の赤い経路のように、訓練データを参照しながら入力の適合性を確認します。学習外と判断した場合は、運転員への警告やAI出力の利用抑制につなげる、という位置づけです。

調査の目的

2:00-2:40 | 40 秒

指図メモ 赤枠と下の目的を指す。前頁の学習手順は繰り返さない。

前の図を、今回の調査目的からもう一度見ます。調べたいのは、この赤枠の検知部分に使える既存のアルゴリズムです。

下には「予測誤差を低減する」とありますが、検知器を付けるだけで回帰器の誤差が自動的に小さくなる、という意味ではありません。信頼性の低い予測をそのまま利用する場面を減らすことを目指します。その効果は、検知結果と実際の回帰誤差の関係を調べて、別に評価する必要があります。

PDF 06 | スライド 04

対象モデルと調査範囲

2:40-4:00 | 80 秒

指図メモ 左の圧力推定、右の処理後濁度、中央の入力条件の順に説明。

対象は、二項目以上の数値を入力し、連続値を出力する回帰モデルです。対象モデルをこの二つだけに限定するわけではありませんが、具体例として説明します。

左側は、送水側の圧力や流量から、ある地点の圧力を推定するモデルです。現在の多変量入力を使って、別の地点の状態を推定します。

右側は、原水の濁度や薬品注入率から、複数の処理工程を経た後の濁度を予測するモデルです。処理には時間がかかるため、入力は時刻 t 、出力はそれより後の時刻の濁度です。この例で予測したいのは処理後の濁度です。

入力は、一時刻のベクトルの場合と、複数時刻をまとめる場合の両方を考えます。センサー値が時系列として記録されていることと、検知器に過去の履歴が必須であることは同じではありません。そこで、今回の調査では、特に一時刻の多変量入力にも適用できるかを確認しました。

PDF 07 | スライド 05

文献一覧

4:00-4:05 | 5 秒

続いて、今回読んだ文献を紹介します。

調査した論文

4:05-5:05 | 60 秒

指図メモ 英文題名を全文読み上げず、各論文の役割を説明する。

読んだ文献は、全体像を整理する三編と、具体的な手法を扱う二編です。

S1は、十六手法を五つのデータセットで比較した論文です。深層学習を含む方法の違いと、評価方法を確認するために読みました。S3は時系列の外れ値検知を広く整理し、S6は深層学習による多変量時系列異常検知を整理しています。この三編から、用語と分類の全体像を把握しました。

具体的な手法として、論文13のOutProと、論文14のAEおよびノイズ除去AEを読みました。OutProは回帰の目的変数やモデル情報を使う方法、AEは入力の再構成を使う方法です。検知の根拠と必要な情報が異なる二つの候補として比較します。

PDF 09 | スライド 07

定義と分類

5:05-5:10 | 5 秒

まず、学習外入力とは何か、どのように分類できるかを整理します。

PDF 10 | スライド 08

本調査における学習外の定義

5:10-6:25 | 75 秒

指図メモ 原因から三ケースへつなぎ、左図と右図を順に指す。

運転条件や環境の変化など、学習外入力が生じる原因はさまざまです。ここでは原因そのものではなく、訓練データに対して入力がどのように異なるかを、三つのケースで整理します。

関連語にはOutlier、Anomaly、Novelty、OOD、分布変化などがあります。ただし、分野や目的によって使い方が違うので、完全な同義語としては扱いません。本調査では、新しい入力が訓練データによって十分に支持されているか、という観点に注目します。

一つ目は左の図です。オレンジの新規入力は、訓練時の観測範囲から外れています。二つ目は右の図です。全体の範囲には入っていますが、訓練点は二つの集まりに集中しており、新しい点の近くにはほとんどありません。つまり、範囲内であっても、十分に学習した領域とは言えない場合があります。

三つ目は、変数の組合せや関係が未知の場合です。次のページで具体的に説明します。

未知の変数間組合せと相関関係

6:25-7:40 | 75 秒

指図メモ 右上の表、左の訓練点、オレンジの点の順。水色の帯を正常領域とは説明しない。

このページでは、各変数を別々に見る場合と、二つを組み合わせる場合を比較します。

右上の表では、新しい流量は約四十、圧力は約七十です。どちらも示された範囲の中なので、各変数の上限と下限だけを確認すれば、問題なしと判断してしまいます。

ところが左の散布図では、訓練点は右上がりに並んでいます。この例では、流量が大きいと圧力も大きい、という関係が訓練データにあります。オレンジの点は、この訓練点の並びから離れています。

つまり、四十という値も七十という値も個別には経験していても、その二つが同時に現れる組合せは十分に経験していません。これが、多変量を共同で見る必要がある理由です。なお、この図は概念を説明する例であり、実際の水系で必ずこの正の関係が成り立つという意味ではありません。

PDF 12 | スライド 10

S1における異常の分類

7:40-9:05 | 85 秒

指図メモ 紫、赤、緑の順。各分類に短い具体例を添える。

ここからは、文献ごとの分類を見ます。S1では、点異常、文脈異常、集合異常という三つを紹介しています。

まず紫色の点異常です。これは、一つの点が他の値から明らかに離れている場合です。例えば、圧力が一回だけ極端に跳ね上がる状況を考えると分かりやすいと思います。

次に赤色の文脈異常です。その値だけなら正常に見えても、時刻や運転状態、他の変数との関係性を考えると異常になります。例えば、ある流量がポンプ稼働中には自然でも、停止中に現れたら不自然、という場合です。図の赤い枠も、二つの系列の対応を合わせて見るのがポイントです。

最後に緑色の集合異常です。一点ずつでは目立たなくても、連続したまとまりやパターンとして見ると異常になります。例えば、本来変動するはずの値が、同じ水準に長くどまる場合です。

この分類は、何を見れば異常だと分かるか、という違いとして理解できます。

S3における点と部分系列の異常

9:05-10:05 | 60 秒

S3では、異常と判定する対象の粒度に注目します。単変量か多変量かという入力の違いと、点、部分系列、系列全体という対象の違いを組み合わせで整理します。

上段の点異常では、特定の時刻の観測を判定します。多変量の場合、圧力だけが異常なこともあれば、流量と圧力の組合せだけが異常なこともあります。

下段の部分系列異常では、連続した区間を一つのまとまりとして見ます。例えば、二十分間の濁度と注入率の動き方が、通常と異なる場合です。図でも、一つの突出した点だけでなく、枠で示された区間全体が対象です。

この違いは、検知器に一時刻を渡すか、時間窓を渡すかを考える際に重要です。

PDF 14 | スライド 12

S3における系列全体と検知目的

10:05-11:05 | 60 秒

続いて、系列全体の異常です。右上では、ある一つの系列が、他の系列とは異なる長期的な動きを示しています。このように、点や短い区間ではなく、系列全体を比較対象とする場合があります。

さらにS3では、外れ値を何のために検知するかも説明されています。右下の一つ目は、通信エラーや計測の誤りなど、修正や除去をしたい不要なデータです。二つ目は、故障や攻撃など、その事象自体を分析したい場合です。

同じ外れた値でも、単に削除すればよいとは限りません。今回も、予測利用を慎重にするための検知なのか、設備の異常原因まで調べたいのかを分けて考える必要があります。

PDF 15 | スライド 13

S6における変数内の時間的異常

11:05-12:20 | 75 秒

指図メモ 右の例図を順に指し、各名称は一文で説明する。

S6は、どの関係が崩れたかという観点で整理できます。このページは、変数内の時間的な挙動です。

まず点単位では、系列全体と比べても大きく外れるGlobal pointと、近くの時刻と比べると外れるLocal pointがあります。右側の例では、全体で見れば珍しくない値でも、その時点の周囲と比べると不自然な場合があると分かります。

パターン単位では、形状、周期、傾向の異常を考えます。右上のShapeletでは波形の一部分の形が変わり、中央のCycleでは繰り返しの間隔が変わります。下のTrendでは、長期的な水準や傾向が通常から外れます。

つまり、異常は一瞬の大きな値だけではありません。値の並び方や時間的な変化そのものを検知するには、履歴を使う設計が必要になる場合があります。

PDF 16 | スライド 14

S6における変数間の異常

12:20-13:35 | 75 秒

指図メモ 上の三系列、下の左赤帯、下の右赤帯の順。

次は、複数の変数の間の依存関係です。

右上のGlobal intermetricの例では、三番目の変数の動きが、他の二つと全体的に異なっています。ここでは、一つの系列だけでなく、系列同士の関係を確認します。

右下の左側の赤い区間はLocal intermetricです。通常は対応して動く二つの変数が、その区間では対応しなくなっています。個々の値がそれぞれの範囲に入っているとしても、組合せとしては不自然です。

右側の赤い区間はTemporal-local intermetricで、変数間の依存関係に加えて、その変数自身の時間的なパターンも外れる場合です。

この整理から、今回の未知の変数関係を見るには、各変数を個別に判定するだけでは不十分だと分かります。一方、時間をまたぐ関係まで対象にするかどうかは、実際の入力仕様に合わせて決める必要があります。

PDF 17 | スライド 15

検知手法の分類

13:35-14:40 | 65 秒

指図メモ 最初に前の分類を短くまとめてから、手法分類へ切り替える。

ここまでを整理すると、S1は何が異常か、S3はどの粒度を判定するか、S6は変数内と変数間のどの関係が崩れるか、という違いがありました。ここからは、異常の種類ではなく、検知する手法の分類です。

S1は従来型、機械学習、DNNという手法群で整理しています。ただし、DNNも機械学習の一部なので、完全に独立した分類ではありません。

S3は、入力の種類、異常の粒度、単変量か多変量の手法か、という複数の観点を使います。S6は、予測、再構成、対照学習といった検知戦略を中心に、学習形態や構造も整理します。

このように分類の目的が異なるので、今回は、必要な入力、検知の根拠、時間履歴、モデル依存を明示して比較することにしました。

PDF 18 | スライド 16

具体的な手法とアルゴリズム

14:40–14:50 | 10 秒

指図メモ 章の切り替えを明確にして次へ。

ここまではサーベイを中心に全体像を整理しました。ここからは具体的なアルゴリズムとして、AEとOutProの仕組みを説明します。

PDF 19 | スライド 17

Autoencoderによる再構成誤差の検知

14:50–16:50 | 120 秒

指図メモ 左の学習、右の推論、下の動作例の順。式は意味を説明する。

まずAEです。考え方は、正常な入力をうまく再構成できるように学習し、新しい入力の再構成誤差を調べる、というものです。

左側が学習です。正常な多変量入力をEncoderに入れて、潜在表現 z に変換します。その後、Decoderを通して元の入力を再構成します。入力と再構成値の差が小さくなるように、両方のパラメータを更新します。このとき、圧力などの回帰の目的変数 Y は不要です。ただし、正常な学習データを準備する必要があります。

右側が運用です。学習済みのパラメータを固定し、新しい入力を再構成します。元の入力との差をスコアとして計算し、閾値と比較します。図では二乗誤差で示しています。論文14ではL2ノルムを用いており、二乗した値やMSEを使う場合には、スコアに合わせて閾値を設定します。

下の例のように、正常な変数関係を学んでいれば、その関係から外れた点の誤差が大きくなることを期待できます。ただし、学習外の入力もうまく再構成する場合がありますので、必ず検知できるわけではありません。

閾値はテスト結果に合わせて後から選ぶのではなく、別の校正データで決めておきます。また、原論文は一時刻ずつ独立に扱うため、今回の単一時刻の多変量数値入力にも対応できます。

PDF 20 | スライド 18

ノイズ除去学習の効果

16:50–17:55 | 65 秒

指図メモ 中央の表のSat AとSat Bを対比。図をすべて説明しない。

論文14では、通常のAEに加えて、ノイズ除去AEも比較しています。これは学習時に入力の一部をゼロにし、元の正常入力を再構成するように学習する方法です。

ここでは中央の表を見ます。Satellite Aでは、通常AEのAUCが約0.885、ノイズ除去AEが約0.935で、改善しています。一方、Satellite Bでは、通常AEが約0.976なのに対して、ノイズ除去AEは約0.836に下がっています。

つまり、ノイズ除去学習を加えれば必ず良くなるわけではありません。左の図はLorenzデータでの再構成誤差などを示していますが、今日のポイントは、同じ方法でもデータによって結果が変わることです。実習データでも、通常AEと拡張版を同じ条件で比べる必要があります。

PDF 21 | スライド 19

VarProとOutProの計算手順

17:55-20:05 | 130 秒

指図メモ 上段から下段へ。参照近傍の箱で止まり、通常のkNNとの違いを補足。

次にOutProです。AEが入力のリ構成を使うのに対し、OutProは回帰の予測に係する変数と、モデルが作る規則を利用します。VarProは重要変数を求める部分で、OutProはその情報を使う検知手法です。

上段の学習では、入力Xと目的変数Yから、教師ありランダムフォレストを学習します。森林の終端ノードには、例えば流量や圧力の範囲を組み合わせた規則があります。VarProによって重要変数の集合Sと重要度を求め、規則や訓練点とともに保存します。

下段では、新しい入力を選択変数の空間で評価します。ここで特に注意したいのが、参照近傍の作り方です。図にはK近傍とありますが、単純に距離が近いK点を選ぶだけではありません。

原手法では、新しい入力を含む規則を取り出し、選択した変数の制約を一つずつ外します。その領域に各訓練点は何回現れるかを集計し、出現回数と変数間の頻度分布から重みを求めます。この重みの上位K点を参照点に選び、その後に距離を評価します。

通常版では、標準化した選択変数空間で参照点までの距離を平均して、OODスコアにします。距離に応じて重要度による重み付けを用います。最後に、運用では閾値と比較して警告などに上げます。

学習時にはYが必要ですが、判定時に新しい入力の真のYは不要です。この点は、処理後の濁度がまだ観測できない場面でも使える可能性につながります。

PDF 22 | スライド 20

OutProの評価結果と制約

20:05-21:20 | 75 秒

指図メモ 左下jointを代表として説明。順位の方向を先に示す。

OutProは六十一の回帰データで評価されています。結果の図は複数ありますが、ここでは左下のjointの順位図を代表として説明します。

横軸は平均順位で、小さいほど上位です。各手法から伸びる線が、その手法の順位につながっています。jointは、各変数を個別に見た分布だけでなく、変数間の依存関係を変えるような条件です。この図では、OutProの複数の距離版が上位に並んでいます。これは、今回関心のある未知の組合せに対して、有望な結果です。

ただし、左上のwarpでは、従来法も上位です。したがって、OutProがどの種類の変化にも最も強い、とは言えません。

また、これらは論文の回帰データと人工的な変化による結果です。水系の時系列データや、今回の回帰器でも同じ効果があるかは、今後確認する必要があります。

PDF 23 | スライド 21

比較と評価

21:20–21:30 | 10 秒

指図メモ アルゴリズムの説明から適用条件と評価へつなぐ。

ここまで二つのアルゴリズムを説明しました。ここからは、今回の対象条件に照らして比較し、どのように評価するかを考えます。

PDF 24 | スライド 23

入力条件と検知できる関係の比較

21:30–22:25 | 55 秒

まず、入力条件です。両手法とも多変量の数値を扱い、一時刻の入力にスコアを付けられます。原論文の方式では過去の履歴は必須ではなく、運用時の真の回帰出力 Y も不要です。

ただし、履歴なしで使えることは、周期や長時間の固定など、時間的な異常をすべて検知できることではありません。

最後の未知の変数関係の行は、どちらも条件付きです。AEは正常な関係の学習と再構成に、OutProは選択変数と参照領域に依存します。表の丸は適用可能という意味であり、性能の保証ではありません。この点を踏まえて、次に対象モデルへの依存を比較します。

PDF 25 | スライド 24

モデル依存と解釈性と計算の比較

22:25–24:05 | 100 秒

指図メモ 適用できる条件を具体例に戻して説明し、最後の問いで次頁へ。

このページでは、最初の目的に戻って、二つの方法を今回のモデルに使えるかを考えます。

AEは、対象回帰器の内部情報を使わず、正常な入力 X で検知器を別に学習できます。したがって、圧力と流量、あるいは濁度と注入率の正常な組合せを学習できれば、回帰器の種類によらず入力監視の候補にできます。

OutProは、学習時にXとY、および教師あり森林を使います。配水の例では入力と対応する圧力、浄水の例では入力と処理後の濁度を、正しく組み合わせる必要があります。対象回帰器が森林以外の場合、補助森林が選ぶ重要変数と対象回帰器の関係も確認します。

どちらも、入力分布が変わらず、入力と出力の関係だけが変わる変化を、入力だけから検知することはできません。また、再構成誤差や重要変数は説明の手掛かりですが、故障原因の断定にはなりません。

計算速度や必要データ量にも、共通の保証値はありません。結論として、両者とも候補にはなりますが、今回の実データでの有効性は未検証です。それでは、その有効性をどう評価すればよいでしょうか。次にデータセットと指標を整理します。

PDF 26 | スライド 25

評価データと評価指標

24:05-25:40 | 95 秒

指図メモ データのラベルと回帰Yを区別してから、警報の例で指標を説明。

評価では、何を入力にし、何を正解の異常とするかを先に決める必要があります。

SWaTとWADIは、水処理や配水に関係する多変量時系列です。ただし、攻撃ラベルは、今回の範囲外、低密度、未知の関係という三条件と同じ意味ではありません。また、回帰の目的変数Yをどの信号にするかも、別に決める必要があります。

PMLBは連続値の目的変数を持つ回帰データです。OutProでは六十一データを使い、warp、joint、supportという人工的な変化を評価しています。回帰の検証には参考になりますが、時系列構造を前提にはできません。

下のPrecisionは、出した警報のうち本当に異常だった割合です。Recallは、実際の異常をどれだけ見つけたかです。例えば警報十件のうち八件が正しければPrecisionは八割で、実際の異常二十件のうち八件を見つければRecallは四割です。

AUROCやAUPRCは閾値を変えた順位性能を見ますが、運用では固定した閾値での誤警報と見逃しも重要です。さらに今回は、検知性能に加えて、警告された入力で実際の回帰誤差が大きいのかも、正しいYが得られるデータで確認します。

PDF 27 | スライド 26

社会インフラへの適用とまとめ

25:40-25:45 | 5 秒

最後に、実運用への適用と今後の課題をまとめます。

社会インフラ適用の観点

25:45-26:55 | 70 秒

社会インフラへの適用では、検知性能だけで方法を決めることはできません。

左の図は概念的な位置づけです。AEは入力を中心に構築し、OutProは目的変数と森林の情報も利用します。上下の位置は、測定した精度や計算量の順位ではありません。

右に示すように、必要な時間内に計算できるか、運転員に説明できるか、誤警報や見逃しがどれくらいあるかを確認します。加えて、季節や運転条件を正常データが十分に含んでいるか、閾値が安定するか、再学習や保守にどの程度の負担がかかるかも重要です。

範囲や距離に基づく単純な方法を基準として、AEやOutProを比較し、必要なら段階的な利用や併用も検討します。ただし、組み合わせれば必ず良くなるということではなく、同じ条件で効果を確認する必要があります。

PDF 29 | スライド 28

まとめと今後の課題

26:55-27:55 | 60 秒

指図メモ 本文を締め、通常は付録を飛ばして謝辞へ。

今回の調査で整理した点は四つです。学習外入力には、範囲外だけでなく、低密度の領域や未知の変数関係も含めて考える必要があります。文献の分類軸は異なるため、検知の根拠と必要情報で比較します。そして、今回の条件では、一時刻の多変量数値入力への適用が重要です。AEとOutProは、その条件に対応する候補ですが、必要データとモデル依存に違いがあります。

今後は入力と出力、時間差、履歴の仕様を確定し、訓練、校正、テストを時間順に分けます。その上で、三条件ごとの検知性能、回帰誤差との関係、処理時間を評価したいと考えています。

現時点では最適な方法を決定した段階ではなく、比較する候補と確認事項を整理した、というのが今回の結論です。

PDF 31 | スライド 謝辞

謝辞

27:55-28:10 | 15 秒

以上で調査報告を終わります。実習中にご指導いただいた皆様に感謝申し上げます。ご清聴ありがとうございました。ご質問やご意見をいただけますと幸いです。

質疑用の付録と発表前の準備メモ

この部分は28分10秒の本文に含めません。

PDF 30 付録A

こちらは、各論文の分類軸を確認するための補足表です。S1の異常の形式、S3の入力と対象の粒度、S6の変数内と変数間の関係、そして深層手法の戦略を、別の観点として並べています。分類名が同じでも意味が一致するとは限らないため、このように分けて確認します。

原稿とページの使い方

PDFの実際の順序に対応しています。付録Aは質疑用で、通常はまとめから謝辞へ進みます。時間は指図とページ送りを含む練習の目安です。日本語版と中国語版は独立して使用し、両方を続けて読みません。

メモの反映箇所

写真1から9の内容は、それぞれスライド02、04、08、10、15、16、20、21、24に反映しています。21の写真の古い転換文は、実際の内容に合わせてアルゴリズムから比較と評価への転換に直しました。

補完する文言

24の仮置き文は「両手法とも候補となるが、必要データ・モデル依存・実機性能の確認が必要」に置き換えられます。謝辞のXxxxxは削除します。03の目的は「信頼性の低い予測の利用リスクを低減する」とすると、回帰誤差が自動的に下がるという誤解を避けられます。

図と数式の確認

09の水色の帯は訓練点と逆向きなので、正の関係に合わせるか削除します。19のK nearest neighborsは「規則解放に基づく参照近傍」とし、頻度による選択を補足します。17の二乗L2ノルムとMSEは定数倍が異なり、MSEでは次元数で割ります。論文14のスコアはL2ノルムです。

その他の確認事項

目次の出典追加メモと04の図替えメモは作業後に削除します。04の予測出力は処理後濁度であり、注入率も同時に予測する図にならないよう確認します。表示ページ22はPDFにありませんが、原稿の順序には影響しません。

時間を調整する場合

試し読みが29分を超える場合、S3の目的分類、S6の各例、AEの結果の数値説明を短くします。未知の変数関係、OutProの参照近傍、対象モデルへの適用条件は残します。約1分50秒の余裕は自然な間のために確保します。