

AI模型运行时的学习外输入数据检测方法

最终版PPT逐页中文演讲稿

目标时长为28分10秒，距离30分钟留约1分50秒余量，包含指图、短暂停顿和换页。实际时间应以一次完整试讲为准。中文稿与日语稿独立使用，不需要将两个版本连续朗读。

本稿逐页对应最终PDF的31页，同时标注PDF页序和幻灯片上印刷的页码。最终PDF中没有显示页码22，因此本稿没有擅自添加该页。

灰色时间和蓝绿色指图提示不朗读。附录A用于答疑，正常汇报从总结页直接跳到致谢页。末尾准备备注也不计入正文。

九张照片中的说明与转场要求已融入正文，包括两个模型仅为例子、异常类型的直观解释、代表性结果图，以及从适用条件到评价方式的过渡。

试讲时的时间检查点

PDF 08 阅读的论文 5:05

PDF 17 检测方法的分类 14:40

PDF 22 OutPro的评价结果与限制 21:20

PDF 26 评价数据与指标 25:40

PDF 29 总结与今后课题 27:55

PDF 31 致谢 28:10

封面

0:00–0:20 | 20 秒

大家好，我是早稻田大学大学院信息生产系统研究科的梁希晨。今天汇报实习期间对AI模型运行时学习外输入数据检测方法的调研，重点讨论这些方法对多变量数值输入回归模型的适用性。

PDF 02 | 幻灯片 00

目录

0:20–0:40 | 20 秒

汇报分为六部分。首先说明背景、研究对象和阅读的文献，再整理学习外输入的定义与分类。之后介绍AE和OutPro的原理及评价结果，最后讨论对本次模型的适用条件和后续课题。

PDF 03 | 幻灯片 01

背景与调研对象

0:40–0:45 | 5 秒

首先介绍调研背景与对象。

PDF 04 | 幻灯片 02

背景与调研目的

0:45–2:00 | 75 秒

指图提示 按上层训练、下层预测、红色检测分支的顺序指图。已加入照片1的memo。

在社会基础设施领域，可以利用传感器数据建立AI模型，估计设备状态或未来数值。这里以预测值作为AI输出的一种例子进行说明，并不是说AI只能输出预测值。

图的上半部分是训练：利用历史输入和对应的真实值，反复更新模型参数。下半部分是运行：固定已经训练好的参数，根据新输入得到输出。

但在实际运行中，运行条件调整、未知环境以及传感器变化，都可能带来训练时未充分包含的输入。此时即使模型仍然能够输出数值，预测的可靠性也可能下降。

因此，我们考虑沿下方红色路径，参考训练数据检查新输入是否适用。如果被判断为学习外，就向操作人员发出警告，或限制AI输出的使用。这就是检测器在系统中的作用。

本次调研的目标

2:00–2:40 | 40 秒

指图提示 指向检测框和下方目标，不重复上一页的训练流程。

从本次调研目的再看这张图，我们要寻找的是能用于红色检测框的现有算法。

下方写着“降低预测误差”，但并不意味着加上检测器后，回归器本身的误差就会自动变小。我们希望减少直接采用不可靠预测的情况。是否真正有效，需要进一步分析检测结果与实际回归误差之间的关系。

PDF 06 | 幻灯片 04

目标模型与调研范围

2:40–4:00 | 80 秒

指图提示 依次说明左侧压力推定、右侧处理后浊度、中央输入条件。已加入照片2的memo。

研究对象是输入至少两个数值变量、输出连续值的回归模型。目标并不只限于这两种模型，这里只是用它们作为具体例子。

左边是利用送水侧压力、流量等，推定某个地点压力的模型。它用当前多变量输入估计另一个地点的状态。

右边是根据原水浊度和药品注入率，预测经过多道工序后的浊度。由于处理需要时间，输入对应时刻 t ，输出对应稍后时刻的浊度。这个例子真正要预测的是处理后浊度。

输入既可能是单时刻向量，也可能包含多个时刻。传感器数据按时间记录，并不等于检测器必须使用历史序列。因此，本次特别确认了方法能否应用于单时刻的多变量输入。

PDF 07 | 幻灯片 05

文献介绍

4:00–4:05 | 5 秒

接下来介绍本次阅读的文献。

PDF 08 | 幻灯片 06

阅读的论文

4:05–5:05 | 60 秒

指图提示 不逐字朗读英文标题，重点说明每篇文献的用途。

阅读的文献包括用于了解整体领域的三篇，以及介绍具体方法的两篇。

S1在五个数据集上比较了十六种方法，用于理解包括深度学习在内的方法差异和评价方式。S3广泛整理时间序列离群检测，S6则聚焦深度学习的多变量时间序列异常检测。通过这三篇，我整理了

用语和分类的整体框架。

具体方法选择了论文13的OutPro，以及论文14的AE和降噪AE。OutPro利用回归目标及模型信息，AE利用输入重构。后面将比较这两种检测依据和信息需求不同的候选方法。

PDF 09 | 幻灯片 07

定义与分类

5:05–5:10 | 5 秒

先整理什么是学习外输入，以及如何分类。

PDF 10 | 幻灯片 08

本次学习外输入的定义

5:10–6:25 | 75 秒

指图提示 先从形成原因过渡到三种表现，再指左右两图。已加入照片3的memo。

学习外输入可能由运行条件或环境变化等多种原因引起。这里不按原因分类，而是按照新输入相对于训练数据呈现出怎样的差异，整理为三种情况。

相关用语包括Outlier、Anomaly、Novelty、OOD和分布变化等，但它们在不同领域和目的下的用法不同，不能视为完全同义。本次关注的是，新输入是否得到训练数据的充分支持。

第一种是左图，橙色的新输入落在训练时观测范围之外。第二种是右图，它虽然处于整体范围内，但训练点集中在两个簇中，新点附近几乎没有样本。因此，范围内也不一定代表这一带已经被充分学习。

第三种是变量组合或关系未知的情况，下一页用具体例子说明。

PDF 11 | 幻灯片 09

未知变量组合与相关关系

6:25–7:40 | 75 秒

指图提示 按右上表、左侧训练散点、橙色点的顺序讲。不要将浅蓝色带解释为正常区域。

这一页比较分别看变量与联合看两个变量的区别。

右上表中新输入的流量约40，压力约70，两者都在表中给出的范围内。因此，如果只检查每个变量的上下限，就可能判断为没有问题。

但左侧散点图中的训练点整体向右上方排列。在这个示例中，训练数据呈现流量越大、压力也越大的关系，而橙色点远离训练点的排列趋势。

也就是说，40和70这两个数值分别都见过，但它们同时出现的组合没有被充分学习。这就是需要联合考虑多个变量的原因。此图只是概念示例，并不表示真实水系统一定存在这样的正相关关系。

S1的异常分类

7:40–9:05 | 85 秒

指图提示 按紫、红、绿依次说明，并加入简短例子。已加入照片4的memo。

下面看各论文的分类。S1介绍点异常、上下文异常和集合异常。

紫色标出的点异常，是单个点明显偏离其他数值。例如压力只在某次采样中极端跳高。

红色标出的上下文异常，是单看数值可能正常，但结合时刻、运行状态或其他变量后变得异常。例如某个流量在水泵运行时很自然，在停机时出现就不自然。图中红框也要结合两条曲线的对应关系观察。

绿色标出的集合异常，是逐点看不突出，但作为连续片段或模式来看异常。例如本来应该变化的数值，在同一水平持续很久。

因此，可以把这三类理解为“需要看什么信息才能发现异常”的不同情况。

PDF 13 | 幻灯片 11

S3的点异常与子序列异常

9:05–10:05 | 60 秒

S3关注被判定对象的粒度，将输入是单变量还是多变量，与检测对象是点、子序列还是整条序列结合起来整理。

上方点异常针对某个时刻的观测。多变量情况下，可能只有压力异常，也可能是流量与压力的组合异常。

下方子序列异常则将连续区间作为整体观察。例如20分钟内浊度与药品注入率的动态模式与平时不同。图中关注的是框出的整段数据，而不仅是一个突出的点。

这种区别对决定检测器输入一个时刻还是一个时间窗口非常重要。

PDF 14 | 幻灯片 12

S3的整条序列异常与检测目的

10:05–11:05 | 60 秒

接着是整条序列异常。右上图中，一条序列的长期变化与其他序列不同。这里比较的是整条序列，而不是单个点或较短区间。

S3还说明了检测离群值的不同目的。右下第一种是通信错误、测量错误等希望修正或去除的数据；第二种是故障或攻击等，需要分析事件本身的情况。

因此，即使数值偏离正常，也不一定应该直接删除。本次同样需要区分：是为了谨慎采用预测结果而检测，还是进一步查明设备异常的原因。

PDF 15 | 幻灯片 13

S6的变量内时间异常

11:05–12:20 | 75 秒

指图提示 依次指右侧例图，每类用一句核心说明。

S6可以从“哪种关系被破坏”的角度理解。这一页关注单个变量内部的时间变化。

点层面包括相对于整条序列也明显偏离的Global point，以及相对于附近时刻才显得异常的Local point。右侧例图说明，一个数值放在全局中可能不罕见，但在当时的局部情境中不自然。

模式层面包括形状、周期和趋势异常。右上Shapelet是局部波形改变，中间Cycle是重复间隔改变，下方Trend是长期水平或趋势偏离正常。

所以异常不只是某一瞬间出现大数值。要识别数值排列和时间变化本身的异常，可能需要使用历史信息。

PDF 16 | 幻灯片 14

S6的变量间异常

12:20–13:35 | 75 秒

指图提示 依次讲上方三条曲线、下方左红带、下方右红带。

接下来是多个变量之间的依赖关系。

右上Global intermetric示例中，第三个变量整体上与另外两个变量呈现不同的变化。需要检查的是序列之间的关系。

右下左侧红色区间属于Local intermetric。通常对应变化的两个变量，在这一区间不再对应。即使各自数值都在范围内，组合作为整体也不自然。

右侧红色区间是Temporal-local intermetric，除了变量间依赖发生偏离，该变量自身的时间模式也发生偏离。

这说明，要识别本次关注的未知变量关系，仅对各变量独立判断并不充分。但是否同时处理跨时间关系，还需要根据实际输入规格决定。

检测方法的分类

13:35–14:40 | 65 秒

指图提示 先总结前面的分类，再转到方法分类。已加入照片5的memo。

先总结前面的内容：S1关注什么表现为异常，S3关注判定对象的粒度，S6关注变量内或变量间的哪种关系被破坏。接下来从异常类型转向检测方法的分类。

S1按传统方法、机器学习和DNN整理，但DNN本身也属于机器学习，因此这些类别并不完全独立。

S3采用输入类型、异常粒度、单变量或多变量方法等多个角度。S6则侧重预测、重构和对比学习等检测策略，同时整理学习形式和结构。

由于分类目的不同，本次比较将明确列出输入需求、检测依据、时间历史与模型依赖。

PDF 18 | 幻灯片 16

具体方法与算法

14:40–14:50 | 10 秒

指图提示 明确从综述转入算法后换页。已加入照片6的memo。

前面主要通过综述整理整体框架。下面进入具体算法，介绍AE与OutPro的工作原理。

PDF 19 | 幻灯片 17

AE重构误差检测

14:50–16:50 | 120 秒

指图提示 按左侧训练、右侧推理、下方示例的顺序。公式讲含义，不逐字符朗读。

首先是AE。基本思路是训练网络重构正常输入，再检查新输入的重构误差。

左边是训练。正常多变量输入经过Encoder转换为潜在表示 z ，再由Decoder重构原始输入。通过减小输入与重构值之间的差异，更新两部分参数。这里不需要压力等回归目标 Y ，但仍然需要准备正常训练数据。

右边是运行。固定训练好的参数，对新输入进行重构，将输入与重构值之差作为检测分数，与阈值比较。图中使用平方误差说明，论文14实际使用L2范数；若改用平方误差或MSE，需要根据相应分数设置阈值。

下方示例表达的是：如果学会了正常变量关系，偏离该关系的点就可能产生较大误差。但AE也可能很好地重构学习外输入，因此不能保证全部检出。

阈值应该用独立校准数据事先确定，而不是看完测试结果再挑选。另外，原论文逐时刻独立处理，因此可以用于单时刻多变量数值输入。

降噪学习的效果

16:50–17:55 | 65 秒

指图提示 重点对比表格中的Sat A和Sat B，不逐图展开。

论文14除了普通AE，还比较了降噪AE。其训练方式是将部分输入置零，再让网络重构原来的正常输入。

这里重点看中间表格。Satellite A上，普通AE的AUC约0.885，降噪AE约0.935，表现改善。但Satellite B上，普通AE约0.976，降噪AE却下降到约0.836。

因此，加入降噪训练并不一定更好。左图展示Lorenz数据的重构误差等结果，本页重点是同一种方法在不同数据上的效果不同。后续也需要在实习数据上，以相同条件比较普通AE与扩展版本。

PDF 21 | 幻灯片 19

VarPro与OutPro的计算流程

17:55–20:05 | 130 秒

指图提示 沿上层再到下层，在参考近邻框处停顿，补充与普通kNN的区别。

接下来是OutPro。AE利用输入重构，而OutPro利用与回归预测有关的变量和模型产生的规则。VarPro负责确定重要变量，OutPro则利用这些信息进行检测。

上层训练阶段，根据输入X和目标Y训练监督随机森林。森林叶节点对应例如由流量、压力范围组合而成的规则。利用VarPro获得重要变量集合S和重要度，并保存规则及训练样本等信息。

下层对新输入在所选变量空间中进行评价。这里特别要注意参考近邻的形成方式。图上虽然写着K近邻，但并不是直接按距离选择最近的K个点。

原方法先找到新输入所属的规则，逐个解除所选变量的约束，统计各训练点出现在释放区域中的次数。再根据出现次数以及次数在变量间的分布计算权重，选择权重最大的K个参考点，之后才计算距离。

通常版本在标准化后的所选变量空间中，平均到参考点的距离，作为OOD分数，并根据距离类型使用重要度加权。实际运行时，再与阈值比较，决定是否警告。

训练时需要Y，但检测新输入时不需要它真实的Y。因此，在处理后的浊度尚未观测到的时刻，也可能应用这种方法。

OutPro的评价结果与限制

20:05–21:20 | 75 秒

指图提示 选择左下joint作为代表，先说明排名越小越好。已加入照片7的memo。

OutPro在61个回归数据集上进行了评价。这里有多张结果图，我选择左下角joint条件的排名图作为代表说明。

横轴是平均排名，数值越小越靠前。每个方法引出的线对应它的排名。joint条件着重改变变量间的依赖关系，而不仅是单个变量的分布。图中多个OutPro距离版本处于前列，这对我们关注的未知变量组合问题是一个有希望的结果。

但左上warp条件下，传统方法也排在前面。因此不能说OutPro对所有变化都是最优。

此外，这些结果来自论文中的回归数据与人工变化。是否对水务时间序列和我们的回归器同样有效，仍需验证。

PDF 23 | 幻灯片 21

比较与评价

21:20–21:30 | 10 秒

指图提示 从算法介绍转到适用条件和评价。照片8重复了上一章节memo，此处按实际内容调整。

前面已经介绍了两种算法。下面回到本次模型的条件，进行比较，并讨论如何评价。

PDF 24 | 幻灯片 23

输入条件与可检测关系

21:30–22:25 | 55 秒

首先比较输入条件。两者都能处理多变量数值输入，并给单时刻输入打分。原论文方式都不强制要求历史，也不需要运行时真实的回归输出Y。

但不需要历史，不代表能发现所有周期异常或长期固定等时间异常。

最后一行的未知变量关系检测，两者都有条件。AE取决于正常关系的学习和重构，OutPro取决于所选变量和参考区域。圆圈表示具备适用条件，不代表性能保证。接下来进一步比较对目标模型的依赖。

PDF 25 | 幻灯片 24

模型依赖 解释性与计算

22:25–24:05 | 100 秒

指图提示 结合两种水务模型说明适用条件，最后用“如何评价”引出下一页。已加入照片9的两条memo。

这一页回到最初的目的：这两种方法能否用于我们的模型？

AE不需要目标回归器的内部信息，可以用正常输入X单独训练检测器。因此，如果能学到压力与流量，或浊度与注入率的正常组合，它就可以作为不依赖特定回归器类型的输入监测候选。

OutPro训练时需要X、Y和监督森林。配水模型中，要把输入与对应压力配对；净水模型中，要把输入与处理后浊度按时间正确配对。如果目标回归器不是森林，还需检查辅助森林选出的重要变量与目标回归器是否一致。

两者都无法仅靠输入，发现输入分布不变、仅输入输出关系变化的情况。另外，重构误差和重要变量只是解释线索，不能直接确定故障原因。

速度与所需数据量也没有通用保证。结论是：两者都能作为候选，但在本次真实数据上的有效性尚未验证。那么应该怎样评价有效性呢？接下来介绍数据集和指标。

PDF 26 | 幻灯片 25

评价数据与指标

24:05–25:40 | 95 秒

指图提示 先区分检测标签与回归目标Y，再用警报例子解释指标。

评价前要先确定输入是什么，以及什么被视为真实异常。

SWaT和WADI是水处理、配水相关的多变量时间序列，但攻击标签不等于本次的范围外、低密度、未知关系三种条件。回归目标Y选择哪个信号，也要另外确定。

PMLB具有连续回归目标。OutPro使用61个数据集，通过warp、joint和support等人工变化评价。它适合作为回归检测的参考，但不能假设这些数据都具有时间序列结构。

下面Precision是发出的警报中真正异常的比例；Recall是实际异常中被发现的比例。例如10次警报有8次正确，Precision就是80%；实际20个异常发现8个，Recall就是40%。

AUROC和AUPRC考察改变阈值时的排序能力，但实际运行还要检查固定阈值下的误报漏报。本次还需在有正确Y的数据上，确认被警告的输入是否确实对应较大的回归误差。

PDF 27 | 幻灯片 26

社会基础设施应用与总结

25:40–25:45 | 5 秒

最后总结实际应用与后续课题。

PDF 28 | 幻灯片 27

社会基础设施的应用要求

25:45–26:55 | 70 秒

应用于社会基础设施时，不能只根据检测性能选择方法。

左图是概念定位。AE主要根据输入构建，OutPro还利用目标变量与森林信息。上下位置不是实际测量的精度或计算量排名。

右侧列出运行需求，包括能否在规定时间内计算、能否向操作人员解释、误报和漏报多少。此外，还要确认正常数据是否覆盖季节和运行条件、阈值是否稳定，以及重新训练和维护的负担。

可以将简单范围或距离方法作为基准，再比较AE和OutPro，必要时考虑分阶段使用或组合使用。但组合不一定更好，同样需要在共同条件下验证。

PDF 29 | 幻灯片 28

总结与今后课题

26:55–27:55 | 60 秒

指图提示 结束正文，正常汇报时跳过附录，进入致谢页。

本次调研主要整理了四点。学习外输入不仅包括范围外，还应考虑低密度区域和未知变量关系。不同文献分类轴不同，需要按检测依据和所需信息进行比较。本次尤其重视单时刻多变量数值输入的适用性。AE和OutPro都是满足这一条件的候选，但数据需求和模型依赖不同。

后续先确定输入输出、时间差和历史规格，再按时间划分训练、校准、测试数据，评价三种条件下的检测性能、与回归误差的关系以及处理时间。

当前尚未确定最优方法，而是明确了可比较的候选与需要验证的事项，这就是本次调研的结论。

PDF 31 | 幻灯片 致谢

致谢

27:55–28:10 | 15 秒

以上就是本次调研汇报。感谢各位在实习期间给予的指导，也感谢大家的聆听。欢迎提出问题和建议。

答疑用附录与演讲前准备备注

本部分不计入28分10秒的正文时间。

PDF 30 附录A

这是用于核对各论文分类轴的补充表。S1的异常形式、S3的输入与对象粒度、S6的变量内外关系，以及深度方法的策略，被作为不同维度并列整理。分类名称相同也未必含义一致，因此需要分开核对。

讲稿与页码

正文按PDF实际顺序覆盖所有页面。附录A只在答疑时讲，正文从总结页直接跳到致谢页。每页的时间是练习目标，包含指图和换页；中日文各自独立使用，不连续朗读两个版本。

memo已融入的位置

照片1对应幻灯片02；照片2对应04；照片3对应08；照片4对应10；照片5对应15；照片6对应16；照片7对应20；照片8对应21；照片9对应24。第21页照片沿用了“接下来介绍算法”的旧memo，讲稿已按实际逻辑改为“从算法转向比较评价”。

建议补全的文字

幻灯片24黄色占位可替换为「両手法とも候補となるが、必要データ・モデル依存・実機性能の確認が必要」。致谢页删除Xxxxx，保留「ご清聴ありがとうございました」。幻灯片03的目标宜表述为「信頼性の低い予測の利用リスクを低減する」，避免暗示检测器自动降低回归器误差。

建议核对的图与符号

幻灯片09浅蓝色带与训练散点方向相反，建议改为与正相关散点一致，或删除该带。幻灯片19的K nearest neighbors建议改为「規則解放に基づく参照近傍」，并补上频次加权选点。幻灯片17中平方L2范数与MSE并非完全同一公式，MSE需除以维数；原论文14采用L2范数。

其他可见待办

目录页仍有“所有图附上出处”，幻灯片04仍有“图替え”；应在PPT中处理后删除。04右侧输出是处理后浊度，建议避免将药品注入率同时画成预测输出。最终PDF缺少显示页码22，不影响本稿讲述顺序。

超时处理

若试讲超过29分钟，可缩短S3第二页的目的分类、S6各子类例子和AE结果页的数值朗读，保留未知变量组合、OutPro近邻机制和模型适用条件。预留的约1分50秒可用于自然停顿，不应再加入大段新内容。