

A Review on Outlier Anomaly Detection in Time Series Data

时序异常检测综述精读研究报告

日本語研究レポート重点版

項目	内容
论文类型	ACM Computing Surveys 综述论文
研究主题	无监督时间序列单点 子序列 整条序列异常检测
重点输出	详细日文研究报告 口头说明稿 想定问答
主要对照	S6 深度 MTSAD 综述 山原论文 OMPB
制作日期	2026年9月8日

本文将论文原文的陈述与本报告针对学習外入力データの解释、工程判断和建议分开表述。

阅读导航

部分	主要内容	用途
第一部分	中文精读与关键公式	建立整体理解
第二部分	详细日本語研究レポート	作为带教汇报主体
第三部分	日本語口頭説明原稿	约 12 到 15 分钟口头汇报
附录	方法标准化与比较表	汇总到最终大型报告

结论先行

- S3 确实是一篇综述。它用输入数据 异常对象 方法性质三条轴组织 2000 至 2019 年的无监督时序异常检测方法。
- 对本研究最重要的内容是三种检测粒度 单点 子序列 整条时间序列，以及多变量方法对变量相关结构的建模。
- 论文的统一思想是先得到正常期望值或正常参照，再用距离 密度 频率 信息量等方式计算偏离，最后通过阈值作出判断。
- 这些方法大多可独立使用输入数据，不需要目标回归模型内部参数。论文中的 model based 是异常检测器自身建模，不等于依赖被监视 AI 模型。
- S3 的检索方法比 S6 透明，但仍是 ad hoc review，未给出筛选数量 质量评价和统一复现实验。它也不提供统一数据集清单或性能排行榜。

第一部分 中文精读

1 文献信息

字段	内容
论文名	A Review on Outlier Anomaly Detection in Time Series Data
作者	Ane Blázquez García Angel Conde Usue Mori Jose A Lozano
发表年	2021
发表先	ACM Computing Surveys 54 3 Article 56 33 pages
DOI	10.1145/3444690
检索范围	主要关键词 time series outlier detection anomaly detection 时间范围 2000 至 2019
数据库	Google Scholar IEEE Xplore ACM Digital Library DBLP Scopus ScienceDirect
版权	2021 copyright held by owner authors 个人或课堂非营利复制按首页声明许可 其他用途需联系权利人

2 论文解决的问题

2.1 背景和重要性

时间序列异常既可能是传感器错误，也可能是故障 攻击 欺诈等有价值事件。不同论文使用 outlier anomaly discord exception 等词，而且输入可能是单变量或多变量，检测对象可能是一个时刻 一段序列或整条变量。没有统一分类时，很难判断两个算法究竟在解决同一问题还是不同问题。

2.2 现有综述的不足

作者认为以往综述多面向一般异常检测，少数涉及时间数据但没有只针对无监督时间序列异常检测，也没有同时整理方法属性和公开软件。

2.3 核心研究问题

- RQ1 哪些特征决定一种时序异常检测方法，怎样建立分类法。
- RQ2 现有方法怎样检测单点 子序列和整条时间序列异常，它们有什么差异。
- RQ3 哪些方法提供公开软件，软件实现了哪类技术。

2.4 核心假设和最终论点

作者把异常的共同本质概括为观测对象显著偏离期望行为。期望行为可以来自同一序列 邻域 历史窗口 外部正常序列 模型预测 聚类中心或密度区域。作者最终要证明，三轴分类加上时间性 流式性 阈值等横向属性，能够比较原本术语混乱的研究。

3 论文结构和每章作用

章节	在讲什么	在整篇论文中的作用
1 Introduction and Methodology	背景 研究问题 检索流程	界定无监督时序异常检测的范围
2 Taxonomy	输入数据 异常对象 方法性质	建立全篇三轴骨架
3 Point Outliers	单变量和多变量的单点检测	说明即时 流式检测的主要技术
4 Subsequence Outliers	连续片段异常	处理形状 周期和集体异常
5 Outlier Time Series	在多条变量中找异常整条序列	处理 entity level 异常
6 Software	公开软件和代码	支持复现与工具选择
7 Conclusions and Future Work	术语 阈值 不规则采样 多变量关系 实时性	总结研究空白

4 Taxonomy 精读

S3 三轴分类与异常对象族



图 1 S3 三轴分类与各异常对象的主要方法族

4.1 输入数据

单变量时间序列在每个时刻只有一个实数，多变量时间序列在每个时刻是 k 维向量。论文理论定义允许缺失和不同粒度，但实际纳入的方法只考虑规则采样且各维时间粒度一致。这一限制对真实传感器系统很重要。

4.2 异常对象

对象	定义	常规异常分类	与学习外输入的关系
Point outlier	某一时刻相对全局或邻域异常	point 或 contextual	可表示范围外 输入突变或低密度点
Subsequence outlier	连续多个点的联合行为异常 单点可各自正常	collective 或 contextual	可表示趋势 周期 组合关系的时段变化
Outlier time series	多变量数据中整条变量或实体行为异常	collective entity level	更接近异常设备 用户或测点 不一定是单次模型输入

4.3 方法性质

单变量方法一次只分析一个变量，即使输入数据包含多个变量，也会忽略变量依赖。多变量方法同时使用多个变量，可以检测每项单独正常但联合关系异常的情况。作者在结论中明确指出，逐变量方法会遗漏相关结构破坏。

4.4 横向比较属性

- Temporality 打乱时间顺序后结果是否改变。
- Streaming 新数据到达时是否能够立即给出判断。
- Incremental 模型能否只利用新增数据更新，而不是从头训练。
- Iterative 是否反复删除或修正已检测异常后再次执行。
- Parametricity 是否假设固定参数分布，包括 parametric semi parametric non parametric。
- Meaning 异常是需要清洗的错误数据，还是需要调查的事件。

5 Point Outliers 精读

5.1 模型式方法

$$|x_t - \hat{x}_t| > \tau$$

式 1 单变量观测相对期望值的偏差

x_t 是时刻 t 的观测, x_t 是正常期望值, τ 是判定阈值。估计式可用当前点和前后数据得到期望值; 预测式只用过去数据, 因此更适合数据到达时判断。 τ 可来自固定倍数 标准差 预测区间 假设检验 极值理论或动态阈值。

二维例子: 压力和流量的观测为 $x_t=(9,1)$, 模型期望为 $x_t=(5,4)$ 。欧氏距离为 $\sqrt{(9-5)^2+(1-4)^2}=5$ 。若 $\tau=4$, 则该联合输入异常。即使 9 和 1 各自在单变量范围内, 联合偏离仍可被多变量模型检测。

$$\|x_t - \hat{x}_t\|_2 > \tau$$

式 4 多变量模型式异常判据

5.2 密度式方法

$$x_t \text{ is anomalous} \Leftrightarrow |\{x \in X : d(x, x_t) \leq R\}| < m$$

式 2 邻域内点数小于 m 时判为低密度异常

R 是邻域半径, m 是最低邻居数量, d 通常为欧氏距离。滑动窗口使密度具有局部上下文, 同一点可能在一个窗口中异常而在另一个窗口中正常。这直接对应用户定义的第②类低样本或低密度区域, 但低密度不自动等于目标 AI 没学好。

5.3 Histogramming 和不相似度

直方图式方法把删除某些点后表示误差显著下降的点称为 deviants。多变量不相似度方法直接比较向量或其表示, 无须显式拟合期望模型。图表示和 RBF 相似度可用于发现与其他多变量点难以相连的节点。

$$s(x_t, \hat{x}_t) > \tau$$

式 5 多变量点的不相似度判据

5.4 阈值和在线性

- 预测式在 x_t 到达后可立即计算残差, 通常不需要未来数据。
- 使用未来点的估计式不能即时判定; 只用过去和当前点的估计式仍需在到达后重算。
- SPOT 和 DSPOT 通过极值理论给出随数据变化的阈值, DSPOT 面向 concept drift。
- 许多方法理论上支持流式输入, 但论文指出实时计算成本缺乏专门验证。

6 Subsequence Outliers 精读

6.1 Discord

$$D^* = \arg \max_D \min_{\{D' \text{ non-overlap } D\}} d(D, D')$$

式 6 Discord 是与最近非重叠片段距离仍最大的子序列

D 是候选子序列, D' 是与 D 不重叠的其他同长度子序列。先找每个 D 最近的参照, 再选其最近距离最大的 D 。它能排序最异常片段, 但经典 discord 没有正常参照和阈值, 往往只能给 top k , 是否真正异常仍需用户决定。

6.2 基于正常参照的不相似度

$$s(S, \hat{S}) > \tau$$

式 7 子序列与期望正常片段的差异

正常参照可来自同一时间序列的聚类中心 外部无异常序列 历史正常片段字典或前一相邻窗口。参照一旦含异常，会扭曲检测。这种无标签但假设参照全正常的方法接近 one class 或 semi supervised anomaly detection。

6.3 预测式 频率式 信息论式

$$\sum_{i=p}^{p+n-1} |x_i - \hat{x}_i| > \tau$$

式 8 一个窗口内累计预测误差超过阈值

$$|f(S) - \hat{f}(S)| > \tau$$

式 9 片段实际出现频率偏离期望频率

$$I(S) \cdot f(S) > \tau$$

式 10 信息量与重复频率结合的异常性

预测式能发现违反动态规律的片段，但逐点递推会累积误差。频率和信息论式常先用 SAX 等方式离散化，适合稀有但重复的模式。它们本质上需要窗口，因此检测延迟至少受到窗口长度影响。

6.4 多变量子序列

$$\sum_{i=p}^{p+n-1} \|x_i - \hat{x}_i\|_2 > \tau$$

式 11 多变量窗口累计预测或估计误差

多变量子序列方法同时处理多个变量并检测时间对齐的异常片段。S3 只总结少量方法，包含非线性变量关系估计 CNN 预测和图不相似度。与第③类学习外输入最相关，但截至论文检索期这一方向仍很薄弱。

7 Outlier Time Series 精读

这一任务不是在一条记录内找异常，而是在多条时间序列或多个变量中找行为整体不同的对象。方法包括从每条序列提取均值自相关等特征后做 PCA，也包括基于聚类 DTW cross correlation 或 shapelet 的整序列不相似度。它适合异常设备 异常用户 异常测点筛查，但不适合直接判断某个单时刻压力估计输入是否学习外。

- PCA 方法依赖所提取统计特征，高密度区域之外的序列被视为异常。
- DTW 允许时间伸缩和不同长度，计算成本高于欧氏距离。
- Shapelet 用代表性局部形状描述正常序列，但外部正常参照必须可靠。
- 论文纳入的整序列方法只有少量研究，证据远少于单点检测。

8 Dataset 要求逐项回答

以下先回答 S3 论文本身是否提供信息，再给出本研究使用时的解释。论文没有像 S6 那样建立 benchmark 数据集表，也没有统一实验。

项目	S3 论文中的情况	对本研究的结论
A 入出力项目	按任务抽象为单变量 x_t 多变量向量 x_t 或长度 n 的子序列 S	输入项目必须由具体应用定义 输出通常为分数 排名或二值异常
B 数据量	没有统一样本数或最低数据量	需要覆盖季节 负荷 控制模式和正常相关结构 不能从综述直接得到数字
C 学习内外标签	范围限定无监督 无统一 ID OOD 正解标签	故障或攻击标签可评价事件检测 但不等同于目标回归模型的学习外标签
D License	没有数据集许可证表 软件仅列链接	每个数据集和代码需按版本单独确认许可
E 异常分类	point subsequence outlier time series 以及 global local	可映射 point contextual collective 但不能完全等同
F 时间结构	实际纳入方法假设规则采样 各变量同一粒度	必须记录粒度 窗口长度 滑动步幅 对齐 缺失值和判定延迟
G 划分和下载	无统一 train test split 或异常占比 软件见 Table 9	实验需重新固定训练期 校准期 测试期 异常注入规则和下载版本
H 输入 only	大多数是独立异常检测器 只需要输入历史或正常参照	不需要目标 AI 内部信息 但预测式检测器需要自身模型和后续实际值

8.1 三类学习外定义的映射

用户定义	S3 中最接近的类别	注意事项
① 分布或输入范围外	global point model based density histogram dissimilarity	异常可以是范围内但概率很低 不能只靠 min max
② 学习数据少或模型未充分学习区域	local density low frequency sparse cluster	S3 检测的是数据稀少 不是直接测目标 AI 的认知不足
③ 单项范围内但组合或相关关系不同	multivariate model based dissimilarity dimensionality reduction	S3 结论明确指出逐变量方法会漏检相关结构破坏

9 检测算法的标准化整理

方法族	正常参照	Score	阈值	运行时信息	主要限制
模型式单点	预测或估计的 x_t	绝对误差 范数 概率	固定倍数 预测区间 ESD EVT 动态阈值	当前输入 历史窗口 自身模型	模型偏差与异常混淆
密度式	半径 R 内邻域	邻居数 局部密度	最低邻居数 m 或 score cutoff	窗口内输入 距离度量	维度灾难 参数敏感
Discord	同序列其他非重叠片段	最近邻距离	通常 top k 无绝对阈值	全序列或滑动窗口	长度预设 计算量高
子序列不相似度	聚类中心 外部正常序列字典 前窗口	距离或重构误差	固定或校准阈值	窗口 正常参照 表示方法	参照污染 窗口依赖
频率 信息论	期望频率或符号规律	频率差 信息量乘频率	预设阈值	离散符号序列	离散化损失 稀有不等于危险
整序列异常	同群体的中心或高密度区域	PCA 距离 DTW 权重	群集或距离阈值	多条完整或长窗口序列	不能即时判断单点

10 评价方法和证据强度

S3 是方法分类综述，没有在统一数据集上复现所有算法。不同原论文使用的标签 指标 预处理 阈值和异常定义不同，因此不能从表格中直接比较检测率或误检率。论文的表主要记录技术属性，不报告统一 AUROC precision recall F1 false alarm rate 检测延迟或计算时间。

- 有正解标签时应报告 point wise 和 event wise precision recall F1 AUROC AUPRC，并同时报告 detection delay。
- 无标签时可使用专家事件记录 人工注入 留出运行模式 稳定性分析和 top k 检查，但这些只能形成间接证据。
- 降低阈值会提高检出率，同时增加误检；提高阈值会降低误检，同时漏掉较弱异常。S3 没有给出统一 ROC 或 PR 曲线。
- 窗口越长越能捕捉长期模式，但检测延迟 计算量和模式混合风险也增加。

- 实时性不能只凭算法形式判断，必须测量每个时刻的计算时间 内存 峰值吞吐和更新成本。

11 长处 短处 制约和适用场景

方面	整理结果
长处	三轴分类清楚 覆盖传统统计 数据挖掘和早期深度方法 解释正常参照和异常粒度 提供公开软件 检索方法比 S6 更透明
短处	检索到 2019 年为止 ad hoc 筛选无流程图和文献数量 无统一实验 无数据集清单 多数方法阈值依赖人工
模型限制	独立 detector 对目标 AI 算法基本无要求 但不同方法要求规则采样 足够正常历史 固定窗口或多条序列
计算限制	Discord 和全对全距离可能平方复杂度 DTW 和重训练较重 流式和增量方法较少
适用案例	传感器错误 设备故障 网络攻击 欺诈 航天遥测 环境监测 异常用户或服务器
基础设施适用	预测残差用于即时监测 密度和多变量不相似度用于组合关系变化 子序列用于持续故障 整序列用于异常测点或设备

12 与山原论文 OMPB 和 S6 的联系

比较项	S3	山原论文	OMPB	S6
主要目的	检测时序数据本身异常	判断压力推定模型的适用领域	分布漂移下在线校准与证书	整理深度 MTSAD
输入粒度	单点 窗口 整序列	以一个时刻的输入向量为	时间序列预测的在线样本	以窗口为主 少量单点
目标模型信息	通常不需要	model independent	需要目标模型预测和 Bayesian head	通常训练独立 detector
最相关方法	密度 多变量不相似度 预测残差	min max 距离 kNN 密度等适用域	posterior disagreement calibration	inter metric anomaly GNN 重构造式
第③类关系异常	多变量模型或不相似度可覆盖	若使用联合距离和密度可覆盖	通过模型不确定性间接反映	local inter metric 明确覆盖

对末端压力推定系统，建议把山原式单时刻 applicability domain 作为第一层，把 S3 的多变量单点密度或不相似度作为第二层，把子序列检测作为第三层。若目标模型可以开放预测分布，再叠加 OMPB 的模型感知校准。

13 社会基础设施监视控制系统的建议

- 前置安全门 对当前压力 流量 阀门 泵状态做范围 密度和联合关系检查，判定必须在控制输出使用前完成。
- 持续状态层 对最近窗口做预测残差或不相似度检测，识别持续泄漏 传感器漂移和异常操作序列。
- 设备群层 定期比较各测点或设备的完整序列，识别异常测点和长期退化设备。
- 阈值治理 用正常校准期设定分位数或可接受误报预算，记录不同阈值下的 recall false alarm 和 delay。
- 异常处置 score 超阈值后不要直接自动停机，应结合物理规则 传感器冗余 操作记录和人工确认，设置 fallback 控制。

第二部分 詳細日本語研究レポート

1 文献情報

項目	内容
論文名	A Review on Outlier Anomaly Detection in Time Series Data
著者	Ane Blázquez García Angel Conde Usue Mori Jose A Lozano
発表年	2021年
発表先	ACM Computing Surveys Vol 54 No 3 Article 56 33 pages
DOI	10.1145/3444690
対象期間	主として2000年から2019年までの文献
論文種別	無教師時系列外れ値検知に関する ad hoc review

2 調査目的と本論文の位置付け

本論文の目的は、時系列データに対する無教師外れ値検知手法を、入力データ、検知対象となる外れ値、検知手法の性質という三つの軸で体系化することである。著者は新しい検知アルゴリズムを提案していない。各研究が用いる outlier、anomaly、discord などの用語を横断して、どのような正常性を仮定し、どの単位で逸脱を検知するかを整理している。

本研究テーマである学習外入力データ検知との関係では、S3 は対象 AI モデルの学習分布を直接定義する論文ではない。S3 が扱うのは入力時系列そのものの異常性である。ただし、入力分布からの逸脱、低密度領域、入力項目間の関係変化を独立 detector で検知するための候補手法を広く含む。このため、model independent な入力監視層を設計する資料として有用である。

3 文献調査方法

著者は三つのモジュールからなる ad hoc methodology を採用した。Database Selection では Google Scholar、IEEE Xplore、ACM Digital Library、DBLP、Scopus、ScienceDirect を使用した。Survey Search では outlier detection、anomaly detection、survey、review、time series を用いた。Literature Search では2000年から2019年を中心に time series、outlier detection、anomaly detection を使用し、univariate、multivariate、time series database、subsequence も補助語として用いた。さらに、抽出文献の参考文献をたどり、方法提案ではない単純な応用論文と高品質な発表先ではない文献を手作業で除外した。

S6 と比較すると、データベース、キーワード、期間、除外方針が明示されている点は優れている。一方、検索式をデータベースごとに再現できる形では示しておらず、検索件数、重複除去件数、一次選別と全文選別の件数、品質評価表もない。そのため systematic review と同等の網羅性や再現性を主張することはできない。

4 用語と問題設定

4.1 Outlier と anomaly

著者は Hawkins の定義を引用し、他の観測から大きく外れ、別の生成機構から生じた疑いを持たせる観測を outlier と捉える。実務上は二つの意味がある。第一は通信エラーや計測誤りのような不要データであり、後続の予測や解析の品質を改善するために削除または修正する。第二は故障、攻撃、詐欺のような調査対象となる事象であり、通常 anomaly と呼ばれる。両者は数理的に同じ score を使う場合があるが、検知後の処置が異なる。

4.2 単変量と多変量

単変量時系列では各時刻の入力は実数 x_t である。多変量時系列では各時刻の入力は k 次元ベクトル $x_t = (x_{1t}, \dots, x_{kt})$ であり、各項目は自分の過去値だけでなく他項目にも依存し得る。論文の定義上は欠損や異なる時間粒度も許容し得るが、レビュー対象手法は原則として等間隔にサンプリングされ、全項目の時間粒度が等しいデータを仮定する。

4.3 外れ値の単位

外れ値単位	定義	入力形式	運用上の意味
Point outlier	一時刻の値またはベクトルが全体もしくは近傍に対して異常	一時刻または短い参照窓	即時判定に最も適する
Subsequence outlier	連続する複数時刻の共同挙動が異常	固定長または可変長 window	継続故障や形状変化を検知
Outlier time series	複数の時系列の中で一系列全体が異常	複数系列または長期間 window	異常設備や異常観測点を抽出

5 本論文における学習外の定義

論文は ID と OOD を明示的に定義しない。最も一般的な定義は、観測された点、部分系列、または時系列全体が expected value または reference of normality から有意に離れている状態である。expected value は予測値だけを意味せず、中央値、平滑値、回帰値、クラスタ中心、高密度領域、過去の正常辞書、外部正常系列、期待出現頻度などを含む。

学習外の観点	S3 における対応	判定時の注意
入力範囲外	global point outlier またはモデル残差の大きい点	範囲内の低確率点や関係異常は min max では検知できない
低密度領域	density based point outlier 疎な cluster 低頻度 subsequence	データ不足と危険事象は同義ではない
未知の項目間関係	multivariate model based dissimilarity dimensionality reduction	各項目を個別に検査すると見落とす
分布変化	DSPOD の concept drift 動的閾値 増分更新	正常変化へ適応し過ぎると異常を正常として学習する
時間的関係の変化	local point subsequence prediction discord frequency	窓長と判定遅延が性能を左右する

6 手法分類基準

最終的な手法比較表では、S3 の三軸に加え、本研究に必要な入力形式、正常参照、score、閾値、対象 AI 情報、オンライン性を記録するべきである。

分類軸	選択肢	分類する理由
入力データ	univariate multivariate	項目間関係を利用できるかを判断する
検知単位	point subsequence entire series	一時刻入力か window 入力かを明確にする
検知根拠	model density histogram discord dissimilarity frequency information theory	score の意味を比較する
正常参照	同一系列 局所窓 過去正常 外部正常 予測モデル cluster	必要データと汚染リスクを整理する
時間性	time order 使用 不使用	シャッフルしても同じ結果になる手法を区別する
運用	streaming batch fixed adaptive incremental	リアルタイム性と保守方法を判断する
対象 AI 依存	input only output aware model aware	山原法や OMPB との違いを整理する

7 Point outlier 検知手法

7.1 Model based

基本 score は観測値と期待値の差である。単変量では $|x_t - x_t|$ 、多変量では $\|x_t - x_t\|$ を用いる。estimation model は過去、現在、場合によっては未来の値から x_t を推定する。prediction model は過去のみから x_t を予測する。したがって、新しい入力に到着した時点で判定する用途には prediction model が適する。

学習時に必要な情報は、正常または異常が少ない履歴、予測または推定モデル、残差分布、閾値校正用データである。運用時には現在入力と必要な過去窓を使う。判定 score は絶対誤差、ユークリッドノルム、尤度、予測区間外れなどである。閾値は固定値、標準偏差倍数、予測区間、ESD 検定、極値理論、Otsu 法、動的 residual threshold など決める。

長所は時間ダイナミクスを直接利用でき、score の意味が明確なことである。短所は、予測モデルの通常誤差と入力異常を分離しにくいこと、運転モード変化で残差が増えること、推定に未来値を用いる場合は即時判定できないことである。

7.2 Density based

半径 R 以内近傍数が最低数 m を下回る場合に異常とする。局所窓を用いれば contextual anomaly を検知できる。学習モデルを明示的に構築しない点は利点であるが、高次元では距離が集中し、R と m の調整が難しい。さらに、低密度であることは学習データ不足を示すが、その入力に対する対象 AI の予測誤差を直接保証するものではない。

7.3 Histogramming and dissimilarity

histogramming は、候補点を別扱いにすることで時系列の区分近似誤差がどれだけ減るかを利用する。dissimilarity based multivariate method は点または表現の pairwise similarity を計算し、他点と関係しにくい点を異常とする。多変量入力の組合せ異常に適する一方、距離尺度、標準化、変数重み、次元数の影響が大きい。

8 Subsequence outlier 検知手法

8.1 Discord detection

discord は、同じ長さの非重複部分系列の中で nearest neighbor distance が最大となる部分系列である。正常ラベルを必要としないこと、形状異常を直接発見できることが利点である。古典的手法では window 長を利用者が指定し、top k の最も珍しい系列を返すだけで、絶対的な異常判定閾値を持たない。この場合、性能評価は既知イベントとの一致、専門家確認、人工注入、順位品質で行う必要がある。

8.2 Dissimilarity based

正常参照は四種類に整理できる。同じ時系列全体を使う方法、外部の正常時系列を使う方法、過去の正常部分系列辞書を使う方法、直前窓を使う局所方法である。score は候補系列と参照系列または cluster centroid の距離である。外部正常参照を用いる場合、ラベルなしであっても正常のみという仮定を置くため、実質的には one class に近い。参照に異常が混入すると閾値と中心が歪む。

8.3 Prediction frequency and information theory

prediction based method は窓内の累積予測誤差を使用する。逐点予測は先の時刻ほど誤差が蓄積するため、subsequence wise prediction の方が長い窓では安定する可能性がある。frequency based method は実際の出現頻度と期待頻度の差を用いる。information theory based method は rare symbol の情報量と反復頻度を組み合わせ、まれだが周期的に現れる部分系列を検知する。これらは離散化を用いる場合が多く、離散化粒度が結果を変える。

8.4 Multivariate subsequence

多変量部分系列では複数項目の時間整合した窓を同時に扱う。モデル式では各時刻の多変量誤差を窓内で合計する。不相似度式では多変量部分系列または graph representation の距離を用いる。入力項目が個別範囲内でも、圧力と流量、弁開度と圧力の応答関係が変われば score が増えるため、第③類の学習外入力に適する。S3 の収録文献ではこの分類の研究数が少なく、periodic multivariate subsequence outlier は未解決とされている。

9 Outlier time series 検知

複数の時系列から異常な系列全体を選ぶ。PCA を使う方法では各系列から平均、一次自己相関などの特徴を抽出し、主成分空間の高密度領域から離れた系列を異常とする。dissimilarity based method では cross correlation、DTW、Jaccard 型 similarity、shapelet を使って系列間距離を求める。DTW は位相ずれや時間伸縮、異なる長さに対応できるが計算量が大きい。

社会インフラでは、複数ポンプ、複数圧力計、複数配水区のうち長期挙動が異なる設備を抽出する用途に適する。ただし、対象 AI に今入力しようとしている一時刻データの適用可否判定には遅すぎる。運用上は定期診断または保全計画向けの層として位置付ける。

10 Dataset の整理

S3 は dataset survey ではなく、各手法の統一 benchmark 実験も実施していない。したがって、以下の項目は論文に記載がないものを明示し、実験設計時に補完すべき情報を整理する。

確認項目	論文記載	研究で追加すべき仕様
入出力項目	x_t ベクトルまたは window という抽象定義	圧力 流量 弁開度 ポンプ状態 時刻 外気等を固定し、検知 score と二値判定を定義
サンプル数	統一値なし	正常運転モード 季節 負荷を十分に含む期間と時刻数を報告
学習内外ラベル	無教師を対象 統一 OOD ラベルなし	対象回帰モデルの学習分布基準と故障イベント基準を分けて作成
利用条件	dataset license 一覧なし	公開元 利用規約 version 商用可否 再配布可否を個別確認
時間粒度	規則サンプリング 同一粒度を仮定	秒 分 時間単位 欠損補間 同期方法を明記
入力単位	point subsequence entire series	一時刻か複数時刻か window 長 stride latency を明記
分割	統一 split なし	時系列順序を維持し train calibration test を分離 異常率と期間を報告
公開性	software link は Table 9 に掲載	dataset download URL checksum version を別表で管理

11 評価方法

11.1 正解ラベルがある場合

point label がある場合は precision、recall、F1、AUROC、AUPRC を報告する。異常が連続区間として定義される場合、point wise 指標だけでなく event wise recall、false alarms per day、検知遅延を併記する。どの時刻を正解区間に含めるか、point adjustment を使うかを明示する。

11.2 正解ラベルがない場合

専門家が確認したイベント記録、保守履歴、物理シミュレーションによる異常注入、正常運転モードの留出、複数手法の一致度、score の安定性を使う。ただし、これらは真の未知分布を完全に代表しない。top k discord のように閾値がない方法は、順位上位に含まれる既知イベント割合や専門家確認時間も評価対象とする。

11.3 検知率と誤検知率

閾値を下げると弱い異常を多く検知できる一方、正常な運転切替やノイズも警報する。閾値を上げると false alarm は減るが、緩やかな漏水や初期故障を見落とす。運用では単一閾値だけを報告せず、PR curve または複数 operating point と、日当たり誤警報数、平均検知遅延を示すべきである。S3 自体は統一評価を行っていないため、手法間の優劣を定量的に決めていない。

12 長所 短所 制約条件

項目	詳細
長所	異常粒度を明確に区別し、正常参照と検知直感を説明している。伝統統計、streaming、discord、初期 deep learning を同じ枠で比較できる。公開 software を整理している。
短所	2019年までの文献であり Transformer、diffusion、contrastive learning など最近の深層手法を含まない。統一 benchmark、dataset 表、実行時間比較、閾値比較がない。
データ制約	ほとんどの手法は規則サンプリングと同一時間粒度を仮定する。多変量手法では同期、標準化、欠損処理が必要である。
計算制約	全ペア距離を使う discord や dissimilarity は長系列で高コストになる。DTW、再学習、クラスタ更新もリアルタイム性を制約する。
閾値制約	自動閾値を持つ手法は少なく、subsequence と entire series では特に不足する。閾値変更が detection rate と false alarm を直接変える。
適用 AI	input only detector として使う限り、対象 AI の回帰、木、NN などのアルゴリズムには原理上依存しない。対象 AI の信頼度を直接測るものではない。

13 山原論文との関係

山原論文は、配水管網の末端圧力推定モデルに対して、入力学習時の適用領域に含まれるかを model independent に評価する。S3 のうち最も近いのは point outlier の density based、multivariate dissimilarity based、dimensionality reduction based method である。いずれも対象回帰モデルの内部情報を必要とせず、現在の多変量入力を学習時入力または正常参照と比較できる。

山原法が一時刻入力を主対象とするのに対し、S3 は window と entire series を明確に分類する。末端圧力では、同じ流量ベクトルでも直前のポンプ切替や弁操作によって意味が変わるため、point AD だけでは不足する可能性がある。S3 の local point と subsequence detection を追加すれば、現在値の位置だけでなく、そこに至る時間的遷移も監視できる。

第③類の学習外入力、すなわち各入力項目は範囲内だが項目間の組合せや相関が異なる場合、各項目を別々に min max 判定しても検知できない。S3 は、多変量相関を無視する手法がこの異常を見落とすと明確に指摘する。したがって、山原式 AD を実装する場合も、joint distance、kNN density、Mahalanobis distance、graph または多変量予測残差を候補に含める必要がある。

14 OMPB および S6 との関係

OMPB は対象 forecasting model の posterior disagreement を利用する model aware なオンライン校正手法である。S3 の prediction based anomaly detection も予測誤差を使うが、多くの場合は異常検知器自身が別の予測モデルを構築する。したがって両者は同じではない。S3 は input only detector を設計し、OMPB は対象モデルの予測不確実性と校正状態を監視する。両者を直列に配置すれば、入力異常とモデル不確実性を分けて説明できる。

S6 は2025年の deep multivariate time series anomaly detection を対象とし、forecasting、reconstruction、contrastive の三分類を示す。S3 はより広く、統計、density、histogram、discord、frequency、information theory を含み、外れ値の粒度と正常参照を詳しく整理する。S3 で問題形式を選び、S6 で最近の deep architecture を選ぶという使い分

けが適切である。

15 社会インフラ監視制御への適用可能性

社会インフラでは、一つの detector に全てを任せず、時間スケールと安全要求に応じた多層構成が適する。第一層は current point に対する applicability domain であり、範囲、距離、密度、項目間関係を入力時点で判定する。第二層は短い window に対する prediction residual または multivariate dissimilarity であり、運転遷移や継続異常を検知する。第三層は長期の outlier time series 検知であり、異常センサや設備劣化を定期診断する。

層	検知対象	候補手法	判定時期	制御上の扱い
Layer 1	現在入力 of 学習領域外	山原式 AD density multivariate distance	対象 AI 実行前	推定停止または fallback
Layer 2	時間遷移と関係変化	prediction residual subsequence dissimilarity	window 完成時	警報 冗長センサ確認
Layer 3	長期異常設備	PCA clustering DTW shapelet	定期バッチ	保全計画とセンサ点検
Model layer	対象 AI の予測不確実性	OMP ensemble uncertainty	予測時と校正時	certificate と再校正

適用時には、正常なポンプ切替や季節需要変化を異常と誤認しないように運転モードを条件として normal reference を構成する必要がある。また detector が新しい入力を正常としてオンライン学習する場合、実故障を正常に取り込まないための quarantine、承認、再学習ルールが必要である。score 超過だけで自動制御を変更せず、物理制約、センサ冗長性、操作履歴と組み合わせる。

16 本論文から得られる重要結論

- 学習外入力を論じる前に、point、subsequence、entire series のどの単位を検知するかを固定する必要がある。
- 各入力項目が正常でも相関構造が異なる場合があるため、社会インフラでは multivariate detector が必要である。
- expected value または reference of normality の設計が手法の中心であり、参照データ汚染は detector 全体を歪める。
- prediction based point detector は即時性に優れるが、subsequence detector は持続的異常を捉える代わりに window 分の遅延を持つ。
- 閾値自動化、実時間計算量、不規則サンプリング、増分更新、多変量周期異常は未解決課題である。
- S3 は方法選択の概念整理には強いが、性能順位や最適手法を決める根拠にはならない。

第三部分 日本語口頭説明原稿

12分から15分の説明

本日は、Blázquez García らの A Review on Outlier Anomaly Detection in Time Series Data について報告します。ACM Computing Surveys に2021年に掲載された33ページの review 論文で、2000年から2019年までの無教師時系列外れ値検出手法を体系化しています。

最初に結論を述べます。この論文の価値は、手法の性能順位を示すことではなく、何を一つの異常として検知するかを整理した点にあります。分類軸は三つです。第一は入力単変量か多変量か、第二は異常が一時刻の point、一つの window である subsequence、または一連全体か、第三は検知手法が一変量ずつ処理するか、複数項目を同時に処理するかです。

本研究テーマとの関係で最も重要なのは、point と subsequence の違い、および univariate method と multivariate method の違いです。例えば圧力と流量がそれぞれ学習時の範囲内でも、その組合せが通常と異なる場合があります。この入力は min max では検知できません。多変量の距離、密度、予測残差、または項目間関係を使う必要があります。これは私たちが定義した第③類の学習外入力に対応します。

Point outlier では三つの代表的な考え方があります。一つ目は model based です。正常時の期待値を予測または推定し、実測値との差が閾値を超えたら異常とします。Prediction model は過去データだけを使うため、新しい入力に到着した時点で判定しやすいです。Estimation model は未来値を使う場合があり、その場合は即時判定できません。

二つ目は density based です。一定半径内の近傍数が少ない点を異常とします。これは学習データが少ない領域、つまり第②類に近いです。ただし低密度であることと、対象 AI が必ず予測に失敗することは同じではありません。三つ目は histogramming または dissimilarity based で、候補点を除くと近似誤差が下がるか、他の多変量点とどれだけ似ていないかを評価します。

Subsequence outlier は、個々の時刻が正常でも連続パターン全体が異常な場合です。代表は discord detection です。各 window について最も近い別 window との距離を求め、その最近距離が最大の window を discord とします。しかし古典的 discord は top k を返すだけで、絶対閾値がありません。したがって、検知結果が本当に異常かは専門家やイベント記録で確認する必要があります。

Subsequence の他の方法は、正常な cluster centroid、外部正常系列、過去正常辞書、直前 window などを reference of normality として距離を計算します。予測式は window 内の累積予測誤差を使い、frequency 式と information theory 式は珍しい繰り返しパターンを検知します。Window を使うため、検知遅延は少なくとも window 長と処理時間に依存します。

Entire time series outlier は、複数の設備やセンサ系列の中から、長期挙動が異なる一列を探る問題です。PCA、clustering、DTW、shapelet などが使われます。これは異常センサや劣化設備の定期診断には有効ですが、末端圧力推定モデルに入力する現在値の安全判定には直接使いにくいです。

Dataset については注意が必要です。この論文は dataset benchmark survey ではなく、統一データセット、サンプル数、train test split、OOD label、license を整理していません。無教師手法を対象としていますが、外部正常系列を使う方法は正常のみという仮定を置くため one class に近いです。私たちが実験する場合は、入力項目、時間粒度、window 長、学習期間、calibration 期間、test 期間、異常率、ラベル作成方法、license を別途固定する必要があります。

評価も統一されていません。ラベルがある場合は precision、recall、F1、AUROC、AUPRC に加え、event wise recall、false alarms per day、detection delay を報告します。閾値を下げれば検知率は上がりますが誤警報も増えます。閾値を上げればその逆になります。社会インフラでは、単一の F1 だけでなく、一日当たり許容できる誤警報数と、故障を何分以内に見つける必要があるかを基準に operating point を選ぶべきです。

山原論文との関係では、山原法は一時刻の多変量入力に対する model independent applicability domain です。S3 の density based と multivariate dissimilarity based method が近いです。ただし S3 は local point と subsequence も扱うため、山原法では見えにくい運転遷移や継続異常を補完できます。

OMP との違いは対象モデル情報です。S3 の多くは入力だけで動く独立 detector です。OMP は対象 forecasting model の posterior disagreement や予測を使う model aware method です。実システムでは、山原式 AD、S3 の window anomaly detector、OMP の model uncertainty を多層化すると、入力の異常、時間パターンの異常、対象モデルの不確実性を分けて監視できます。

本論文の限界は、調査が2019年までであり、最近の Transformer、diffusion、contrastive learning を含まないこと、統一実験と dataset 表がないこと、閾値の自動決定と実時間計算量の検証が不足していることです。一方、S6 よりも outlier の粒度、正常参照、streaming、incremental update を明確に整理しています。したがって S3 で問題設定を決め、S6 で最近の model architecture を選ぶ使い方が有効です。以上です。

想定質問と回答

質問	回答要点
この論文は systematic review ですか	データベース、キーワード、期間は示すが ad hoc methodology と明記され、PRISMA 型件数と品質評価がないため systematic review と同等ではない。
学習外入力を直接定義していますか	ID OOD は定義しない。expected value または normal reference からの逸脱として outlier を定義する。
入力だけで検知できますか	多くは可能。detector 自身の履歴、正常参照、予測モデルは必要だが、対象 AI の内部情報は通常不要。
model based は対象 AI 依存ですか	ここでの model は detector が正常値を予測または推定するモデルであり、監視対象 AI とは別である。
第③類に最も適した分類は何ですか	multivariate model based または dissimilarity based。各項目別検査ではなく joint vector と相関を評価する。
一時刻入力なら何を使いますか	山原式 AD、multivariate density、distance、prediction residual。未来値を使う estimation と window 完成待ち は事前判定に不向き。
Discord に閾値がない問題はどうしますか	top k 順位として利用し、専門家確認または校正データで閾値を追加する。既知 event の ranking recall も評価する。
SWaT や WADI をこの論文の dataset として使えますか	S3 は統一 dataset 一覧を示さない。S6 など別資料で version、split、label、license を確認して採用する。
リアルタイムに使えるという根拠は十分ですか	理論上 streaming 対応でも、S3 は実測 latency を比較していない。対象環境で worst case time と memory を測る必要がある。
正常変化と異常をどう区別しますか	運転モード別参照、物理制約、change point、複数 detector、操作履歴を組み合わせる。自動適応には異常汚染防止が必要。

附录 方法标准化一览

检测对象	方法族	输入	正常参照	Score	閾値	学習外対応	输入 only
Point	Estimation	point plus context	全序列或前后窗口	$ x - \hat{x} $	统计倍数 检验 动态	① ③	是
Point	Prediction	past window plus point	历史预测模型	预测残差 尤度	预测区间 EV T	① ③ 漂移	是
Point	Density	point or local window	邻域样本	neighbor count density	R m 或分位数	② 兼顾①	是
Point	Histogram	ordered points	最优直方图	删除前后近似误差	deviant 数或误差	①	是
Point	Multivariate dissimilarity	k dimensional point	历史 joint samples	vector graph distance	距离分位数	③	是
Subsequence	Discord	fixed or variable window	同序列其他窗口	nearest neighbor distance	top k 或后校准	① ② ③ collective	是
Subsequence	Dissimilarity	window	cluster 外部 正常 字典 前窗	sequence distance	固定或校准	③ contextual	是
Subsequence	Prediction	past window and observed window	预测模型	累计预测误差	误差分位数	漂移 collective	是
Subsequence	Frequency information	discretized window	期望符号频率	频率差 信息量	预设阈值	② 稀有模式	是
Entire series	PCA clustering DTW shapelet	多条完整系列	群体中心 高密度区	距离 权重	cluster 或距离	异常设备 entity	是

参考文献

1 Blázquez García A Conde A Mori U Lozano J A A Review on Outlier Anomaly Detection in Time Series Data ACM Computing Surveys 54 3 Article 56 2021 DOI 10.1145/3444690

2 山原裕之ほか 配水管網における圧力推定のための機械学習モデルの適用領域の検討

3 Huang C et al Model Agnostic Online Certificate Driven Calibration for Time Series Forecasting Under Distribution Shift UAI 2026

4 Wang F et al A Survey of Deep Anomaly Detection in Multivariate Time Series Taxonomy Applications and Directions Sensors 2025 25 190