

Model-Agnostic Online Certificate-Driven Calibration

论文精读与研究分析

中文精读 日本語研究レポート 口頭説明原稿

項目	内容
研究主題	多変量時序回归模型在分布变化下的学習外输入监测与在线校准
主要論文	Huang, Ma, Michailidis (2026) OMPB
対照論文	山原・横山・金谷 配水管網における压力推定のための機械学習モデルの適用領域の検討
制作日期	2026年9月8日

本报告将 OMPB 作为精读对象。山原论文仅用于说明末端压力推定场景中的对应关系，不对其进行逐章精读。

阅读导航

部分	内容	使用方式
第一部分	中文深度精读	用于真正理解论文结构、概念、公式和实验
第二部分	日本語研究レポート	可直接整理后向带教提交
第三部分	日本語口頭説明原稿	用于当天 7 到 10 分钟口头汇报
附录	术语和预想问答	应对追问并追加到最终总报告

核心判断

- OMPB 的主要目标是分布变化下的在线预测校准，而不是输出一个具有固定阈值的 ID OOD 二分类结果。
- 它在预测前只使用当前输入窗口，但必须调用目标模型和 Bayesian head 生成多次预测，因此不是严格意义上的输入数据独立检测器。
- 输入侧 mismatch 可以在真实输出尚未到达时立即计算；真实输出到达后，系统再按照 predict then update 原则更新轻量 head。
- 论文的 certificate 约束有界代理风险，不直接上界实验报告中的原始 MAE 或 MSE。作者本人明确限制了这一解释。
- 与山原方法相比，OMPB 更适合时间窗口和在线适应；山原方法更适合单时刻、多变量、模型外置式的适用域判定。

第一部分 中文深度精读

1 文献信息

字段	内容
论文名	Model-Agnostic Online Certificate-Driven Calibration for Time Series Forecasting Under Distribution Shift
作者	Chenfeng Huang, Zixuan Ma, George Michailidis
年份	2026
发表处	Proceedings of the 42nd Conference on Uncertainty in Artificial Intelligence, PMLR 337, 2244-2273
会议形态	UAI 2026 Oral
方法简称	OMPb Online Martingale PAC-Bayes
代码	https://github.com/chenfeng-huang/OMPb-UAI-2026
论文主页	https://proceedings.mlr.press/v337/huang26b.html

2 论文到底在解决什么问题

2.1 用通俗语言理解

时间序列预测模型通常使用过去一段时间的数据预测未来。但是上线后的季节、设备、地点、制度和运行方式会变化，部署数据可能不再像训练数据。模型可能仍然给出一个看似正常的数字，却已经进入训练时没有充分覆盖的状态。

传统在线更新依赖真实输出。多步预测中，真实输出要经过一个预测期以后才出现，因此更新时使用的标签可能已经属于旧状态。另一类 PAC-Bayes 理论可以给出风险证书，但经典推导常假设样本独立同分布；时间序列具有相关性和非平稳性，直接套用会产生过度乐观或无效的保证。

作者提出的问题是：能否在当前真实输出尚未到达时，利用当前输入窗口和模型预测分歧感知分布变化；等到输出到达后，只进行保守的小范围校准，同时给这一过程建立适合相关时间序列的有限样本理论依据。

2.2 研究背景和重要性

- 时序数据相邻时刻高度相关，有效独立样本数明显小于观测点数。
- 多步预测存在标签延迟，不能在预测当前时刻时偷看未来真实值。
- 部署变化既可能是 $P(X)$ 改变的 covariate shift，也可能是 $P(Y|X)$ 改变的 concept shift。
- 社会基础设施中，激进在线更新会把短时噪声或旧状态误学进模型，可能比不更新更危险。

2.3 现有方法的不足

现有方向	不足	OMPb 的应对
普通再训练	需要及时标签，容易追赶已经过去的状态	严格采用先预测后更新，冻结 backbone
SOLID 等在线校准	依赖检索或调参策略，理论风险控制有限	把 certificate 作为更新正则项
OneNet 等在线集成	强变化和延迟监督下可能不稳定	只更新轻量 Bayesian head 并设置 gate
经典 PAC-Bayes	常用 i.i.d. 集中不适合相关时序	改用 martingale concentration
纯输入距离检测	未必只关注与预测任务有关的方向	使用后验预测分歧作为任务相关 mismatch

2.4 核心问题 假设和想证明的内容

- 核心问题：如何在依赖、非平稳且反馈延迟的时序流中进行可计算的在线风险监视和稳定校准。
- 核心假设一：源数据可以写成带过滤信息的随机过程，损失增量满足有界或条件 sub-gamma 条件。
- 核心假设二：Bayesian head 的后验样本在陌生输入上会产生更大的预测分歧，因此分歧可作为输入侧 shift 信号。
- 核心假设三：把高维 backbone 固定，只对低维 residual head 做 Bayesian 更新，可使 KL 复杂度可计算并降低更新失稳。
- 论文要证明的理论部分：在时间依赖下仍可构造 martingale PAC-Bayes domain adaptation bound。
- 论文要验证的实证部分：该 certificate 驱动的校准在 covariate shift 和 concept shift 设置下，比三个在线基线更稳定、预测误差更低。

3 整体结构

章节	内容	在整篇论文中的作用
Abstract	问题 方法 主要结论	给出 OMPb 的整体定位
1 Introduction	分布变化 标签延迟 i.i.d. 理论不足	建立研究动机并提出三项贡献
2 Related Work	时序泛化界 PAC-Bayes 领域适应 在线校准	说明理论和工程来源
3 Preliminaries	shift 类型 martingale PAC-Bayes bound	给出方法成立所需定义和定理
4 OMPb	gated residual Bayesian head 离线训练 在线校准	定义完整算法
5 Performance Assessment	数据集 基线 指标 主实验 消融	验证预测效果和模型无关性
6 Discussion	certificate 行为 head 表达能力	解释工程取舍
Appendix	证明 数据细节 shift 验证 概率指标 敏感性 延迟	补足主要限制和可复现信息

4 Introduction 精读

4.1 这一节在讲什么

这一节把三个问题连在一起：部署分布变化、时间序列相关性、多步预测标签延迟。作者认为，理想方法必须在预测时只利用已经看到的输入感知变化，并在标签后来到达时保守地更新。

4.2 作者为什么要讲这个

它为方法设计中的每个部件提供理由：输入侧 disagreement 解决即时感知，martingale 解决时间依赖，Bayesian head 解决可计算 KL，gate 和冻结 backbone 解决延迟监督下的稳定性。

4.3 关键概念

概念	定义和数学含义	直观含义	与学习外入力的关系
Covariate shift	$P(X)$ 改变而 $P(Y X)$ 不变	输入环境变了但规律没变	对应输入范围 分布或组合关系变化
Concept shift	$P(Y X)$ 改变	同样输入产生不同输出	可能不伴随可见输入 OOD 因而更难检测
Delayed feedback	y 在预测之后 D 步才可用	当前不能用答案判断当前状态	要求预测前的检测不能依赖目标值
Certificate	由源风险 复杂度 mismatch 组成的代理量	风险警示仪表而非绝对误差预测	可作为软告警和更新强度依据

4.4 真正重要的结论

- 作者把检测与适应设计成一个系统，而不是孤立的二分类器。
- 预测时不得使用尚未到达的真实输出，这是评价在线方法时最重要的因果约束。
- 论文所谓 model agnostic 是对 backbone 架构不敏感，不等于完全不访问模型。

5 Related Work 精读

5.1 这一节在讲什么

相关工作从风险上界、领域适应和可微 PAC-Bayes 目标出发，解释为什么可以把理论 certificate 变成训练时的 surrogate regularizer。

5.2 作者为什么要讲这个

作者需要同时回答两个问题：理论上为什么允许在相关时序上构造界，以及工程上为什么最小化这个界可以成为更新规则。

5.3 必须理解的概念

概念	解释
Population risk	目标分布上的期望损失，部署前通常未知
Empirical source risk	源训练或 replay 数据上的经验损失
Prior π 与 posterior ρ	head 参数在更新前后的概率分布
KL complexity	posterior 偏离 prior 的程度，更新越激进惩罚越大
Domain discrepancy	源输入和目标输入在 posterior 预测分歧上的差
Martingale	在已知过去信息后，下一步随机增量的条件期望受控

$$R_T(h_\rho) \leq \hat{R}_S(h_\rho) + \Gamma_m^{\text{sub}\gamma}(\rho, \pi, \delta) + \frac{1}{2} \text{dis}_\rho(S, T) + \lambda_\rho$$

式 1 OMPb 所依据的 PAC-Bayes 领域适应结构

变量解释：RT 是目标风险，RDS 是源经验风险， Γ 是与时间依赖 方差 KL 和置信度有关的复杂度项，dis 是源目标的预测分歧差， λ_ρ 是依赖目标标签的不可识别残差项。直观上，目标风险不只取决于训练误差，还取决于模型改动幅度和当前输入与训练输入的差异。

5.4 真正重要的结论

- 理论结构清楚地分离了源性能 模型复杂度 输入 mismatch 和不可识别标签变化。
- 在线阶段无法使用 λ_ρ ，因此实际 certificate 只是可计算部分，不是完整目标风险上界。

6 Preliminaries 精读

6.1 这一节在讲什么

第 3 节先定义 covariate shift 与 concept shift，再用 Freedman 型和 sub-gamma 型 martingale concentration 取代 i.i.d. concentration。

6.2 作者为什么要讲这个

这是论文最主要的理论贡献。若不处理相关性，同一季节连续出现的相似样本会被错误地当作大量独立证据，certificate 会过于乐观。

6.3 关键概念

概念	数学含义	直观含义
Filtration $\mathcal{F}_t$	截至 t 时刻可获得的信息集合	算法当时真正知道什么
Conditional variance V_m	逐步条件方差的累计	数据越不稳定 风险修正越大
Sub-gamma	条件矩生成函数由方差代理 v 和尺度 c 控制	允许未剪裁回归损失但要求尾部不能任意重
Finite-sample guarantee	有限 m 下以至少 $1-\delta$ 概率成立	不是只有无限数据才成立的渐近结论

6.4 与学习外入力的关系

Martingale 理论本身不直接判断某个输入是否 OOD。它的作用是让源风险与复杂度修正在时间依赖下更可信。真正对输入变化敏感的是后续的 posterior disagreement。

6.5 真正重要的结论

- 该理论适合流式时序，而不是把窗口随机打乱后假设独立。
- 应用前需要检查损失尾部与 variance proxy 的合理性。
- 理论保证针对代理损失，不自动转化为原始 MAE MSE 的严格保证。

7 OMPb 方法精读

OMPb の予測時点と更新時点



图 1 OMPb 的因果在线流程

7.1 Gated residual Bayesian head

A 这一节在讲什么：固定原预测模型，只在其输出后追加一个轻量 Bayesian residual head。head 学习对原预测的修正，gate 决定修正量是否启用。

B 作者为什么要讲这个：对整个深度模型做 Bayesian 化会使 KL 项过大、计算昂贵；在延迟标签下更新整个模型也容易失稳。

$$\hat{y}(w) = z(w) + s(z(w)\Delta W^\top + \Delta b), \quad s = \sigma(\alpha)$$

式 2 Gated residual correction

$z(w)$ 是 backbone 的 H 步预测； ΔW 和 Δb 是修正参数； s 是 0 到 1 的 gate。 s 接近 0 时输出退回原模型。对于多变量预测，论文在 disagreement 中进一步用 C 表示目标变量数。

$$\text{KL}(\rho \parallel \pi) = \frac{1}{2} \sum_{i=1}^P \left(\frac{\sigma_i^2 + \mu_i^2}{\sigma_0^2} - 1 - \ln \frac{\sigma_i^2}{\sigma_0^2} \right)$$

式 3 对角高斯 posterior 与各向同性 prior 的 KL

μ_i 和 σ_i 是 posterior 参数， σ_0 是 prior 标准差， P 是 head 参数数。 μ 过大或 posterior 方差与 prior 偏离过大，KL 都会增大，从而抑制过度更新。

- 优点：适配 TCN Autoformer GPT4TS 等不同 backbone。
- 限制：必须增加 Bayesian head 并进行 posterior sampling，不能把任意封闭黑盒直接当成纯输入检测器。

7.2 离线训练

A 这一节在讲什么：先用源数据训练 backbone，再让 head 从接近零修正开始学习；同时缓存源 replay 样本和损失尺度统计。

B 作用：保证上线第一步不会突然改变原模型，并为后续源风险 anchor 和 martingale correction 准备参考数据。

- 训练时需要带标签的源窗口和已训练 backbone。
- head 的离线目标由源监督损失和 KL prior penalty 构成。
- 论文将 KL 权重设为 $1/N$ ，并在各数据集使用固定 head training size。

7.3 在线 disagreement 和 mismatch

A 这一节在讲什么：对同一目标输入窗口，从 posterior 抽取 K 个 head，比较它们的预测差；再比较目标窗口的平均分歧与源窗口的平均分歧。

$$\tilde{d}_{\tau_d}(h, h'; w) = \min \left\{ 1, \frac{\|h(w) - h'(w)\|_2^2}{HC\tau_d^2} \right\}$$

式 4 有界 posterior 预测分歧

H 是预测步数，C 是预测变量数， τ_d 是尺度。除以 HC 后，不同预测维度可以比较；min 截断确保分歧在 0 到 1 范围内。

$$\tau_{\text{auto}} = \sqrt{\text{Quantile}_q \left(\frac{\|h^{(k)}(w) - h^{(k')}(w)\|_2^2}{HC} \right)}, \quad q = 0.5$$

式 5 源 replay 自动确定分歧尺度

论文采用 $q=0.5$ ，即源数据 posterior 两两预测差 RMS 的中位数。注意： τ_d 是归一化尺度，不是 OOD 二分类阈值。

$$\hat{d}_\rho(w) = \frac{2}{K(K-1)} \sum_{1 \leq k < k' \leq K} \tilde{d}_{\tau_d}(h^{(k)}, h^{(k')}; w)$$

式 6 单个输入窗口的平均 posterior 分歧

$K=5$ 时共有 10 对比较。 K 较大可以降低抽样波动，但成对比较数量为 $K(K-1)/2$ ，计算量二次增长。

$$\widehat{\text{dis}}_\rho(t) = \left| \frac{1}{m} \sum_{i=1}^m \hat{d}_\rho(w_i) - \frac{1}{|W_{T,t}|} \sum_{w' \in W_{T,t}} \hat{d}_\rho(w') \right|$$

式 7 源窗口与当前目标窗口的 mismatch

二维数值例：若 $H=C=1$ 、 $\tau_d=2$ ，两个 posterior 模型分别预测 10 和 13，则分歧为 $\min(1, 9/4)=1$ 。若源窗口平均分歧为 0.10、当前目标窗口平均为 0.60，则 mismatch 为 0.50，certificate 中增加 0.25。

- 这一步不使用当前 y ，因此可以在预测前执行。
- 但它调用模型输出和 posterior，因此不属于只看原始输入数值的检测。
- posterior collapse 会产生假阴性；posterior 过宽会产生假阳性。

7.4 在线 certificate 和更新

$$\widehat{\text{PB}}_Y(t) = \widehat{R}_{S,t}(h_\rho) + \Gamma_m^{\text{suby}}(\rho, \pi, \delta) + \frac{1}{2} \widehat{\text{dis}}_\rho(t)$$

式 8 可计算的在线 certificate

源 replay 风险负责不遗忘原任务， Γ 负责时间依赖和 posterior 复杂度，mismatch 负责反映当前输入窗口与源域差异。 $\lambda\rho$ 因需要当前目标标签而被省略。

$$\mathcal{L}_{\text{cal}}(t; \rho) = \widehat{\text{PB}}_Y(t; \rho) + \widehat{R}_{T,t}^{\text{sup}}(\rho)$$

式 9 标签到达后的校准目标

预测发出以后 y 才进入监督损失。算法只更新 head，backbone 始终冻结。该顺序避免 look-ahead bias。

$$\Pr_{(w, y) \sim T}(\|y - h(w)\|_2 \geq \tau) \leq R_{T, \tau}(h), \quad \ell_\tau = \min \left\{ 1, \frac{\|y - h(w)\|_2^2}{\tau^2} \right\}$$

式 10 有界代理风险与大误差概率的关系

这个推论说明，如果代理损失采用截断平方损失，代理风险上界也可上界误差超过 τ 的概率。但 τ 太小时大量误差都会饱和为 1，太大时中等误差几乎不可见，因此 certificate 不等同于 MAE 或 MSE。

7.5 检测算法整理

环节	学习时需要	运行时需要	得分或输出	阈值
源参考建立	带标签源窗口 源 replay posterior prior	无	源风险与源分歧基线	无二分类阈值
预测前监测	已训练 backbone 与 Bayesian head	当前输入窗口 WT,t	disagreement mismatch certificate	论文未给告警 cutoff
预测	固定 backbone	当前输入窗口	H 步多变量预测	不适用
预测后更新	源 replay	延迟到达的 yt	校准 loss	gate 连续控制

8 数据集和学习外定义

数据集	输入输出与粒度	划分与样本数	学习外定义	公开与许可
ETTh	7 变量 小时级 输入 96 时刻 预测 H=24 96 336	ETTh1 80% 训练 13,745 窗口 20% ID 3,293; ETTh2 抽相同数量 OOD	地点和变压器不同引起 covariate shift; 全部 ETTh2 窗口按 OOD 域处理	GitHub 公开; 仓库未见明确数据许可证, 企业使用需确认原始数据权利
ILI	11 变量 周级 输入 24 周 预测 H=24 48 72	2009-2020 pre-COVID 中 80% 训练 443 窗口 20% ID 108; 2021-2026 COVID 抽 108 个 OOD	作者称 concept shift; 整个 COVID 时期按 OOD 域处理	CDC FluView 可获取; 多数 CDC 材料属公有领域但需署名并避免暗示背书, 具体字段需复核
WEATHER-5K	6 变量 小时级 输入 96 小时; 展示温度多步预测	Miami 90% 训练 78,764 窗口 10% ID; Atlanta 与 NYC 各抽 8,646 OOD	跨地点 covariate shift; Atlanta near OOD, NYC far OOD	GitHub 和 OneDrive 下载; 仓库标注 MIT, 但原始气象数据再分发条款仍需确认

8.1 数据类型和输入单位

- 三个实验都是多变量时间序列, 输入不是单个时刻, 而是连续 24 或 96 个时刻组成的窗口。
- 一次模型调用同时读取多个时刻的多变量值, 并输出未来 H 个时刻的预测。
- 因此论文不能直接证明对山原场景中单时刻输入向量的有效性。若要应用, 需将末端压力模型改成窗口模型, 或另外构造 window encoder。
- 论文表 5 只给出 feature 数量, 没有完整列出 ILI 和 WEATHER-5K 的所有输入列及目标列。报告不把仓库字段推测当成论文事实。

8.2 正解标签的有无和定义

论文有 ID OOD 域标签, 但不是逐点人工标注的异常标签。ETTh2 COVID 期 Atlanta NYC 被研究者按来源整体定义为 OOD; ID 则来自源地点或源时期的测试段。没有证明每个 OOD 域窗口都真正困难, 也没有把切换点逐点标注。

按用户要求中的三类学习外定义, ETTh 和 WEATHER-5K 主要属于①输入分布或范围外, 也可能包含③变量组合与相关关系变化; ILI 被作者归为 concept shift, 但附录同时显示很强的输入分布变化, 因此它同时具有①或③证据。论文没有专门构造②低密度但仍在整体范围内的实验。

按 anomaly 分类, 它们更接近 contextual 或 collective anomaly, 因为异常性由地点 时期和连续窗口决定, 不是单一孤立 point anomaly。

9 实验与结果精读

9.1 评价方法

类别	内容
预测指标	MAE MSE; 附录含 NLL CRPS 80% 95% coverage interval width ECE
比较方法	Original SOLID OneNet PROCEED
Backbone	TCN Autoformer GPT4TS
检测信号验证	certificate 与实际 MAE MSE 的 Pearson Spearman 相关; disagreement 与 KS Wasserstein JS MMD 的相关
消融	去除 gate 去除 PAC-Bayes 项 去除在线更新; 另比较 last-layer 和 LoRA 在线更新
稳健性	td K variance proxy normalization feedback delay posterior miscalibration

9.2 代表性结果

设置	Original	OMPb	解读
ETTh TCN H=96 OOD ETTh2 MAE MSE	2.5635 8.9076	0.5570 0.5912	预测误差大幅降低
ILI GPT4TS H=48 OOD COVID MAE MSE	1.3013 4.2179	0.9263 2.6351	在 concept shift 设置下改善
ETTh TCN H=96 delay 1 step to 2H	0.5570 0.5912	1.8608 2.7751	标签延迟 性能越差
每步运行 ETTh TCN H=96 K=4	约 103.08 ms	约 9.70 steps/s	可在线但需按控制周期评估

检测信号与错误的相关性并不总是很强。certificate 对目标 MAE 的 Pearson Spearman 分别为 ETTh 0.592 0.278、ILI 0.507 0.276、WEATHER-5K 0.239 0.439。它更适合作为风险监视信号，不能当作精确误差估计器。

9.3 检测率与误检率

论文没有报告逐窗口 OOD 检测的 AUROC AUPR precision recall FPR 或固定阈值结果。因此无法从本文直接得到检测率与误检率的数值 trade-off。论文比较的是预测误差和信号相关性。若将 certificate 用作报警器，需要在独立 ID 校准段上设定分位数阈值，再用跨地点 跨季节和已知事件回放评价每小时误报率 检出率和检测延迟。

9.4 消融和真正的结论

- 去掉 PAC-Bayes 正则或在线校准，多个 shifted stream 的误差明显恶化。
- 额外更新 backbone 的 last layer 或 LoRA 在三组诊断中都比冻结 backbone 更差，支持保守更新设计。
- K 从 2 增至 16 几乎不改变代表性设置的误差，K=32 因 496 对比较使每步时间增至 239.59 ms。
- 不进行 clipping 的 disagreement 数值失稳，说明有界性不仅是理论形式，也是工程稳定条件。

10 方法分类和适用性

分类标准	是否属于	理由
输入范围和规则	否	不逐变量检查 min max
输入距离和近邻	间接	比较源目标分歧均值，但距离位于预测空间而非原始输入空间
输入概率密度	否	不显式估计 p(X)
特征表示和重构	否	无 autoencoder reconstruction score
预测不确定性	是 核心	Bayesian posterior 样本分歧表示 epistemic uncertainty
模型间不一致	是 核心	同一 Bayesian head 的 K 个 posterior predictor 两两比较
预测残差	用于更新	源风险和延迟标签监督损失使用误差，但预测前 mismatch 不用当前残差
时序窗口	是	输入为连续 24 或 96 时刻窗口
分布变化监测	是	比较源和当前目标窗口的平均 disagreement
在线适应	是 核心	certificate 驱动 Bayesian head 更新

10.1 输入依赖和模型依赖

问题	结论
只用输入数据能否检测	当前 y 不需要，但需要把输入送入 backbone 和 Bayesian head 并读取 K 个预测，因此不是独立的 input-only detector
需要内部信息吗	需要 head posterior 参数和采样预测；backbone 可当固定前向模块，但部署系统必须可追加 head
需要输出吗	监测阶段需要模型预测输出；在线校准阶段还需要延迟真实 y
支持什么模型	论文验证 TCN Autoformer GPT4TS；原则上适合能输出 H 步数值预测且可附加 head 的回归 forecaster
单时刻输入可用吗	论文没有验证。理论可令窗口长度为 1，但时序相关结构和实验结论不能直接继承

11 长处 短处和约束

方面	长处	短处或约束
理论	处理时间依赖和有限样本；避免直接套用 i.i.d.	依赖 sub-gamma 或 bounded proxy 假设；完整 λp 在线不可得
检测	预测前用当前输入窗口产生 shift 信号	无二分类阈值和检测率评价；纯 concept shift 可能不可见
适应	只更新轻量 head；gate 可退回 backbone	需要改造部署模型并维护 posterior 和 source replay
实时性	K=5 只有 10 对比较；约 100 ms 每步的代表性结果	硬实时可否满足取决于设备 控制周期 和 backbone；K 增大为二次成本
数据	无需目标 OOD 标签即可开始监测	离线仍需带标签源数据；持续改善依赖延迟 y
可解释性	certificate 可分解为源风险 复杂度 mismatch	分值不是 MAE MSE 的紧上界，单位和业务危险度不直接对应

12 对论文证据的批判性判断

1. 论文证明的是有界代理风险的 certificate 结构，不是原始回归误差的严格实时上界。
2. 实际在线式省略了依赖目标标签的 λp ，因此不能覆盖仅有 $P(Y|X)$ 变化而输入侧不变的纯 concept shift。
3. ILI 被称为 concept shift，但附录 KS Wasserstein JS MMD 显示输入分布也发生显著变化。这一实验不能单独证明对纯 concept shift 的检测能力。
4. 所有目标域窗口整体标成 OOD，没有逐窗口真假标签，也没有报警 threshold。因此本文更强地证明在线校准有效，而不是证明 OOD 检测分类性能。
5. model agnostic 的范围是 backbone family，不是零侵入黑盒。若现有系统不能追加 Bayesian head 或取得多次预测，该方法无法直接部署。
6. 实验仅覆盖三个 benchmark 和三种 backbone，尚未验证水务系统中的传感器故障 模式切换 缺失值 强物理约束和安全联锁。

13 与山原论文的联系

比较项	OMPb	山原论文	对末端压力推定的意义
主要目标	分布变化下的在线风险监测和预测校准	确定压力推定模型的 applicability domain	山原更直接回答是否可使用当前预测；OMPb 还能校正预测
输入单位	24 或 96 时刻的多变量窗口	某一时刻的配水场压力 流量 阀门状态等向量，时刻类别不参与 AD	现有单时刻模型可直接用山原方法；OMPb 需窗口化
检测依据	posterior 预测分歧的源目标差	minMax 均值距离或 kNN 密度，欧氏或 Mahalanobis 距离	山原直接覆盖范围 低密度和变量相关关系
目标模型依赖	需要 backbone 输出和 Bayesian head	AD 判断可在目标模型外部运行	山原更容易追加到既有系统
真实输出	预测前不需要；预测后校准需要延迟 y	AD 判定不需要真实末端压力；评价时需要实测压力误差	两者都能在推定前发出风险信息
阈值	τ_d 为归一化尺度；无告警 cutoff	训练样本最大距离或 kNN 最大平均近邻距离等规则	山原已形成明确内外判定；OMPb 需另行设计报警阈值
实验结论	改善 shifted forecasting 的 MAE MSE	综合判断 kNN Mahalanobis 最优	可考虑 kNN Mah 作为一级输入门卫，OMPb 作为二级窗口监测和校准

13.1 山原论文提供的直接工程基准

- 比较 5 种 AD：minMax tCD Euclidean tCD Mahalanobis kNN Euclidean kNN Mahalanobis，k 固定为 5。
- 训练数据天数 N 为 14 28 91 182；模拟一年数据，剩余日期用于评价。
- 评价关注 AD 外比例 AD 内外误差差异，以及假定绝对误差超过 0.022 MPa 为 AD 外时的 accuracy recall precision F 值。
- 总体推荐 kNN Mahalanobis，因为兼顾变量相关性 局部密度和较稳定的误差分离。

14 社会基础设施监视控制系统中的适用方案

1. 第一级传感器质量检查：缺失 固着 突跳 越物理范围和通信异常。此级用于把 sensor fault 与运行状态变化初步分开。

2. 第二级山原式 input-only AD：对单时刻压力 流量 阀门开度计算 kNN Mahalanobis 和 minMax，给出可解释的输入适用域判定。
3. 第三级 OMPb 窗口监测：若系统可以保存最近 24 或 96 个采样时刻，则用 posterior disagreement 检测持续性和组合关系变化。
4. 第四级安全动作：certificate 超过经验证阈值时，不直接自动控制，而是降低预测可信度 扩大安全余量 切换物理模型或请求人工确认。
5. 第五级在线校准：只在真实末端压力可靠到达并经过传感器质量确认后更新 head；保留 frozen backbone 和 gate 作为回退路径。

14.1 新运行状态与传感器故障的区分

OMPb 本文没有解决这一问题。工程上应联合判断：单传感器是否孤立突变、多个相关变量是否同步变化、变化是否持续、是否与阀门操作 泵切换 季节和维护记录一致、物理平衡是否被破坏。新运行状态通常表现为多个变量协调而持续的改变；传感器故障更常出现孤立 不连续或违反物理关系的变化，但不能只靠这一经验规则作最终判断。

15 本篇结论

- 适用性评级：对多变量时序回归高度相关，对单时刻末端压力模型只能间接适用。
- 分类：预测不确定性 模型分歧 时序分布变化 在线校准的复合方法。
- 学习外覆盖：主要覆盖①和③；没有专门证明②；纯 concept shift 可能漏检。
- 最大价值：把即时输入侧监测与延迟监督下的保守更新统一起来。
- 最大缺口：没有可直接使用的 ID OOD 告警阈值，也没有检测率和误检率曲线。
- 对末端压力系统的建议：先保留山原式 kNN Mahalanobis 作为独立输入门卫，再评估 OMPb 作为时间窗口型二级风险信号。

第二部分 日本語研究レポート

1 文献情報

項目	内容
論文名	Model-Agnostic Online Certificate-Driven Calibration for Time Series Forecasting Under Distribution Shift
著者	Chenfeng Huang, Zixuan Ma, George Michailidis
発表年	2026年
発表先	The 42nd Conference on Uncertainty in Artificial Intelligence PMLR 337 pp 2244-2273
提案手法	Online Martingale PAC-Bayes OMPb

2 調査結果の要点

OMPb は、分布シフト下の多変量時系列予測に対して、予測時点で利用可能な入力窓からモデル間不一致を算出し、ラベル到着後に軽量の Bayesian residual head のみを更新する手法である。従って、学習外入力 of 監視機能を持つが、主目的は ID OOD 二値判定ではなく、certificate に基づくオンライン較正である。

本手法は対象モデルの内部に Bayesian head を追加し、複数の posterior prediction を必要とするため、入力データだけで独立に検知する方法ではない。一方、予測時点では正解出力を必要とせず、遅延ラベルによる未来情報漏洩を避けている。

3 学習外の定義

観点	本論文での扱い
入力範囲または分布外	ETTh1 から ETTh2、Miami から Atlanta NYC への covariate shift として扱う
低密度領域	明示的な評価設定はない。posterior disagreement が増える可能性はあるが保証されない
項目間関係の変化	多変量入力窓に対する予測分岐として間接的に捉える。原入力相関を直接測定しない
Concept shift	ILI の pre-COVID と COVID で評価。ただし入力分布差も大きく、純粋な concept shift の検証ではない
異常分類	地点や期間に依存する contextual anomaly または連続窓の collective anomaly に近い

4 手法分類

- AI モデルの予測不確実性に基づく手法
- 複数 posterior predictor 間の不一致に基づく手法
- 時系列窓に基づく分布変化監視手法
- PAC-Bayes certificate に基づくオンライン較正手法
- 予測後の遅延ラベルを利用する残差更新手法

5 検知アルゴリズム

1. 学習済み backbone を固定し、出力に gated residual Bayesian head を追加する。
2. 学習時に source replay buffer、source risk、posterior prior 間 KL、損失尺度統計を準備する。
3. 運用時に直近の target input window を backbone と K 個の posterior head に入力する。
4. 同一入力に対する K 個の予測の二乗差を HC と τ_d で正規化し、0 から 1 に clipping する。
5. source window と target window の平均 disagreement の差を mismatch score とする。
6. source risk、martingale correction、mismatch の半分を加算して online certificate を得る。
7. 予測を先に発行し、正解値の到着後に certificate と supervised loss で head のみを更新する。

判定スコアは disagreement、source target mismatch および certificate である。 τ_d は source replay における posterior 予測差の中央値から決めるが、これはスケールであり、ID OOD の判定閾値ではない。論文は警報用の二値閾値を提示していない。

6 データセット

Dataset	入出力と時間粒度	分割	OOD 正解の定義
ETTh	7変量 1時間 96時刻入力 H=24 96 336	ETTh1 80% train 20% ID test ETTh2 を同数 OOD	ETTh2 の採用窓を domain-level OOD とする
ILI	11変量 1週間 24時刻入力 H=24 48 72	pre-COVID 80% train 20% ID test COVID を同数 OOD	2021-2026 の COVID 期間を OOD とする
WEATHER-5K	6変量 1時間 96時刻入力	Miami 90% train 10% ID Atlanta NYC を各 8646 OOD	Atlanta を near OOD NYC を far OOD とする

公開方法は ETTh が GitHub、ILI が CDC FluView、WEATHER-5K が GitHub から案内される OneDrive である。WEATHER-5K repository は MIT License を表示する。ETT repository では明確な data license を確認できないため、業務利用前に原データの権利を確認する必要がある。CDC 資料の多くは public domain であるが、出典表示と非推奨表明が求められる場合がある。

7 評価方法と結果

予測性能は MAE と MSE を中心に評価し、NLL、CRPS、区間被覆率、区間幅、ECE を補足評価している。比較手法は SOLID、OneNet、PROCEED、未校正 Original であり、backbone は TCN、Autoformer、GPT4TS である。

代表設定	Original	OMPb	評価
ETTh TCN H=96 ETTh2	MAE 2.5635 MSE 8.9076	MAE 0.5570 MSE 0.5912	大幅改善
ILI GPT4TS H=48 COVID	MAE 1.3013 MSE 4.2179	MAE 0.9263 MSE 2.6351	改善
ETTh TCN H=96 delay 2H	delay 1 step MAE 0.5570	delay 2H MAE 1.8608	ラベル遅延で悪化

一方、OOD 検知器としての AUROC、AUPR、false positive rate、event recall は報告されていない。従って、検知率と誤検知率の trade-off は本文から定量化できない。certificate と実誤差の相関も dataset によって中程度または弱く、certificate は警戒信号として解釈すべきである。

8 長所と短所

長所	短所
時間依存を martingale concentration で扱う	sub-gamma 条件と variance proxy の妥当性確認が必要
予測前に current input window から shift signal を計算できる	純粋な concept shift は input-side disagreement だけでは検知できない可能性がある
backbone を凍結し gate で安全側へ戻れる	Bayesian head の追加と posterior sampling が必要
異なる forecaster family で改善を確認	3 dataset 3 backbone の範囲であり、社会インフラ実機検証はない
source risk complexity mismatch に分解可能	certificate は raw MAE MSE の直接上界ではない

9 適用制約

- 対象は数値時系列予測モデルであり、連続した複数時刻を一度に入力する。
- 入力長 1 への理論的変更は可能でも、本文では単一時刻入力を評価していない。
- source labeled windows、source replay、delayed target labels を保存できる必要がある。
- posterior calibration が崩れると disagreement の選択性が低下する。
- 代表設定では約 100 ms per step であるが、制御周期別に end-to-end latency を再測定する必要がある。
- binary alarm threshold は別途 ID calibration data と業務上の許容誤報率から設計する必要がある。

10 山原論文との対応

山原らの方法は、配水場の圧力 流量、連絡調整弁の開度 流量 圧力など、ある一時刻の多変量入力から末端圧力を推定するモデルを対象とし、minMax、training center distance、kNN density を Euclidean または Mahalanobis distance で比較する。OMPb と異なり、対象 AI の内部情報を必要としない input-only applicability domain 判定である。

共通点は、学習データで安全に性能を発揮できる入力領域を定義し、運用時の過大な推定誤差リスクを事前に把握する点である。相違点は、山原法が一時刻ごとの明示的 AD 内外判定であるのに対し、OMPb は時間窓に対する連続 certificate とオンライン較正である点にある。

末端圧力推定への導入では、山原論文が推奨する kNN Mahalanobis を一次判定に残し、十分な履歴と遅延実測圧力が確保できる場合に OMPb を二次監視として追加する構成が妥当である。

11 社会インフラ監視制御への適用可能性

項目	評価
適用可能性	中から高 ただし時系列窓型予測とモデル改造が可能な場合
適用候補	配水末端圧力 需要量 流量 ポンプ負荷 電力需要 気象影響設備の予測
安全上の使い方	直接自動停止ではなく、信頼度低下表示、安全マージン拡大、fallback model 切替、運転員確認
追加評価	季節 設備切替 センサ故障 通信欠損 未知運転モードを含む chronological backtest
運用指標	一日当たり誤警報、event recall、検知遅延、制御判断への影響、更新時間、rollback 成功率

12 結論

OMPb は、学習外入力検知、予測不確実性、オンライン較正を結合した有力な複合手法である。ただし、単独の ID OOD classifier として完成しているわけではなく、告警閾値と検知性能評価を別途設計する必要がある。末端圧力推定モデルに対しては、山原式 input-only AD の代替ではなく、時間的变化と予測較正を担当する補完層として位置付けるべきである。

第三部分 日本語口頭説明原稿

7分から10分の説明

今日は、Huang らの Model-Agnostic Online Certificate-Driven Calibration for Time Series Forecasting Under Distribution Shift について報告します。この論文は UAI 2026 の Oral paper で、提案手法は OMPb と呼ばれています。

最初に結論を述べます。OMPb は一般的な OOD 二値分類器ではありません。現在の入力窓に対する予測モデルの不一致を用いて分布変化を監視し、その信号を使ってオンライン較正を安定化する方法です。従って、学習外入力検知と予測モデル更新を一体化した手法と理解するのが適切です。

背景には二つの問題があります。一つ目は、時系列モデルを運用すると、季節、地点、設備、運転状態の違いにより、入力分布や入力から出力への関係が学習時から変化することです。二つ目は、多段予測では正解値が遅れて到着することです。現在の予測を出す時点では正解値を使えず、正解値が来た時には状態がさらに変わっている可能性があります。

そこで OMPb は predict then update を採用します。予測前には、現在までの入力窓だけを利用します。ただし、raw input だけを見るのではなく、固定した backbone と Bayesian head に入力し、K 個の posterior prediction を生成します。K 個の予測が大きく分岐する入力は、モデルが十分に理解していない可能性が高いと考えます。

具体的には、同じ入力窓に対する予測差を 0 から 1 に clipping し、その平均を disagreement とします。次に、source data の平均 disagreement と、現在の target window の平均 disagreement の差を distribution mismatch とします。論文では K を 5 とし、10 組の予測ペアを比較しています。

online certificate は、source risk、martingale correction、distribution mismatch の三つから構成されます。martingale を使う理由は、時系列データが独立ではないためです。通常の i.i.d. PAC-Bayes bound をそのまま使うと、連続する似たデータを独立な証拠として数え、リスクを過小評価する可能性があります。

予測を出した後に正解値が到着すると、certificate と supervised loss を使って Bayesian head だけを更新します。backbone は凍結され、gate が小さい場合は元の予測へ戻ります。この設計により、古くなったラベルでモデル全体を過剰に更新する危険を抑えます。

実験には ETTh、ILI、WEATHER-5K の三つの多変量時系列 dataset が使われています。入力は一時刻ではなく、ETTh と WEATHER-5K では 96 時刻、ILI では 24 時刻の窓です。ETTh1 から ETTh2、pre-COVID から COVID、Miami から Atlanta または New York への移行を OOD としています。

代表例として、ETTh の TCN、予測 horizon 96 では、OOD ETTh2 の MAE が original 2.5635 から OMPb 0.5570 に低下しました。ILI の GPT4TS、horizon 48 でも、COVID 期間の MAE が 1.3013 から 0.9263 に改善しました。ただしラベル遅延が 1 step から 2H へ長くなると性能は大きく悪化します。

重要な注意点が三つあります。第一に、certificate は raw MAE や MSE の厳密な上界ではなく、bounded proxy risk の監視信号です。第二に、論文は OOD 検知の AUROC や誤検知率を報告せず、binary threshold も示していません。第三に、model agnostic とは backbone の種類を選ばないという意味であり、input-only の外付け検知器という意味ではありません。

山原論文との関係について説明します。山原論文は、ある一時刻の配水データを対象に、minMax、中心距離、kNN 密度と Euclidean または Mahalanobis distance で applicability domain を決定します。特に kNN Mahalanobis が総合的に望ましいと結論しています。これは対象モデルの内部情報を必要としない input-only 方法です。

従って末端圧力推定モデルには、山原式 kNN Mahalanobis を一次の入力適用域判定として使用し、履歴窓と遅延実測圧力を利用できる場合に OMPb を二次の時系列監視と較正に用いる構成が考えられます。OMPb 単独でセンサ故障と新しい運転状態を区別することはできないため、物理ルール、複数センサの整合性、運転操作履歴を併用する必要があります。以上です。

想定質問と回答

質問	回答要点
これは入力だけで検知できますか	現在の正解値は不要ですが、backbone と Bayesian head の複数予測が必要です。従って raw input-only ではありません
一時刻入力にも使えますか	理論上 window length 1 は可能ですが、論文は 24 または 96 時刻窓だけを評価しており、別検証が必要です
OOD の閾値はどう決めますか	本文は告警閾値を示していません。ID calibration 期間の上位分位点と許容誤報率から別途設定します
Concept shift も検知できますか	入力側に変化が現れない純粋な concept shift は難しいです。遅延ラベル到着後の残差で補う必要があります
山原法より良いですか	目的が異なります。山原法は単時刻の外付け AD 判定、OMPb は窓型の監視とオンライン校正であり、補完関係です
社会インフラで直ちに使えますか	直接制御より warning と fallback に使い、センサ品質確認と chronological backtest を追加するのが安全です

用語集

用語	中文解釋	日本語での説明
PAC-Bayes	用经验风险和模型复杂度控制总体风险的理论	経験リスクと prior posterior 間 KL から汎化リスクを評価する枠組み
Martingale	在已知过去信息下控制随机增量	過去の情報に条件付けて時系列の依存を扱う確率過程
Posterior disagreement	多个后验模型对同一输入的预测差	同一入力に対する posterior predictor 間の予測不一致
Certificate	风险监控用可计算代理量	source risk complexity mismatch を統合した監視指標
Gated residual head	在原预测上追加受门控的小修正模块	backbone 予測へ残差補正を加え、不確実時は gate で抑制する head

参考文献

- [1] Huang C, Ma Z, Michailidis G. Model-Agnostic Online Certificate-Driven Calibration for Time Series Forecasting Under Distribution Shift. Proceedings of UAI 2026, PMLR 337, 2244-2273.
<https://proceedings.mlr.press/v337/huang26b.html>
- [2] Huang C, Ma Z, Michailidis G. OMPb-UAI-2026 official implementation.
<https://github.com/chenfeng-huang/OMPb-UAI-2026>
- [3] 山原裕之 横山雄 金谷道昭. 配水管網における圧力推定のための機械学習モデルの適用領域の検討.
- [4] Zhou H et al. ETT Dataset. <https://github.com/zhouhaoyi/ETDataset>
- [5] Centers for Disease Control and Prevention. FluView Interactive. <https://www.cdc.gov/fluview/>
- [6] Han T et al. WEATHER-5K. <https://github.com/taohan10200/WEATHER-5K>
- [7] McAllester D. Some PAC-Bayesian Theorems. COLT 1999.
- [8] Germain P et al. PAC-Bayesian Theory Meets Bayesian Inference. 2020 and related domain adaptation results cited by the target paper.
- [9] Freedman D. On Tail Probabilities for Martingales. Annals of Probability, 1975.