

A Survey of Deep Anomaly Detection in Multivariate Time Series

综述论文精读与研究分析

中文精读 日本語研究レポート 口頭説明原稿

項目	内容
论文类型	Review article 多变量时间序列异常检测综述
研究对象	深度学习 MTSAD 的分类 方法族 数据集 应用与未来方向
主要对照	OMP 以及山原桑的末端压力推定适用域研究
制作日期	2026年9月8日

本报告以 S6.pdf 为精读对象。论文中的方法描述与本报告的批判性判断、工程建议分别标明。

阅读导航

部分	内容	用途
第一部分	中文深度精读	理解综述结构 分类标准 公式 方法族和数据集
第二部分	日本語研究レポート	向带教提交的正式整理内容
第三部分	日本語口頭説明原稿	约 8 到 12 分钟汇报及预想问答
附录	方法与数据集标准化表	用于最终大型总报告

先说结论

- 这是一篇方法地图型综述，不是系统评价或 meta-analysis。作者没有报告文献检索数据库、检索式、时间范围、纳入排除标准或质量评价流程。
- 作者的一级分类是预测式、重构式和对比学习式，共列出 46 个模型，其中 15 个预测式、22 个重构式、9 个对比学习式。
- 对本研究最有价值的是它对 temporal anomaly 与 inter-metric anomaly 的区分。后者直接对应各输入项仍在范围内但组合关系发生变化的学习外输入。
- 绝大多数新方法使用滑动窗口。表 1 中只有 4 个模型标为 point input，其余 42 个标为 window input。
- 该综述关注系统数据是否异常，不直接判断某个目标回归模型能否可靠预测。其异常标签也多是故障或攻击事件，不等同于回归模型的 ID OOD 正解。

第一部分 中文深度精读

1 文献信息

字段	内容
论文名	A Survey of Deep Anomaly Detection in Multivariate Time Series Taxonomy Applications and Directions
作者	Fengling Wang Yiyue Jiang Rongjie Zhang Aimin Wei Jingming Xie Xiongwen Pang
发表年	2025
期刊	Sensors Volume 25 Issue 1 Article 190
DOI	10.3390/s25010190
论文性质	Review 开放获取 CC BY 4.0
收录范围	作者表 1 整理 46 个深度 MTSAD 模型 表 2 整理 31 个公开数据集或 benchmark

2 论文到底在解决什么问题

2.1 通俗解释

复杂系统会同时记录压力 流量 温度 阀门状态 CPU 网络流量等多个量。异常可能是某一项突然尖峰，也可能是每项都看似正常、但彼此关系已经被破坏，还可能是一段时间的趋势 周期或形状异常。传统统计和距离方法在高维 非线性 强时间依赖条件下容易受限，因此需要整理深度学习怎样同时学习时间关系和变量间关系。

作者要做的不是提出一个新的检测器，而是建立一张方法地图：异常有哪些类型，方法按照什么原则分类，不同神经网络适合捕捉什么结构，有哪些公开数据集和应用场景，未来还缺什么。

2.2 为什么重要

- 单变量检测会漏掉变量组合和相关关系破坏。
- 工业和基础设施异常通常连续发生，并具有上下文和运行模式依赖。
- 异常标签稀少且类别极不平衡，监督分类往往不现实。
- 模型结构越来越多，若只按 backbone 罗列会混淆检测依据和输入需求。

2.3 作者的核心问题和假设

- 核心问题：如何从异常类型、学习范式和深度模型结构三个角度组织近年的 MTSAD 方法。
- 核心假设：预测误差、重构误差和表征差异可以覆盖大部分深度 MTSAD 的判定逻辑。
- 核心假设：时间依赖和变量间依赖是多变量异常检测的两个基本维度。
- 最终想说明：统一分类有助于选择方法，公开数据集和未来方向能够推动更真实 更可解释的研究。

2.4 需要提前知道的限制

论文自称 structured and comprehensive overview，但没有给出系统综述常见的检索协议。因而不能确认是否穷尽文献，也不能把模型数量或优缺点视为经过一致实验验证的排名。论文主要依据原文叙述进行定性比较，没有在统一代码 统一预处理 统一阈值下重新实验。

3 整体结构

章节	内容	作用
1 Introduction	背景 传统方法局限 贡献	说明为什么需要深度 MTSAD 综述
2 Background and Preliminary	问题定义 异常类型 时频域	建立术语与数学对象
3 Taxonomy	分类总览 学习范式 输入形式	给出全篇组织骨架
4 Forecasting Methods	CNN RNN GNN Transformer	解释预测残差路线
5 Reconstruction Methods	AE VAE GAN Transformer Diffusion	解释重构路线
6 Contrastive Methods	LLM MLP Mixer Transformer	解释表征差异路线
7 Datasets	31 个 benchmark 10 类应用域	提供数据资源
8 Conclusions and Future Direction	四类未来方向	总结研究空白

4 Background and Preliminary 精读

4.1 这一节在讲什么

作者先把 MTS 写成 T 个时刻 C 个变量的矩阵，再要求算法为每个时刻输出 anomaly score。随后从单变量的时间异常和多变量的 inter-metric 异常两条轴定义异常。

4.2 作者为什么要讲这个

如果不先定义异常，就无法判断某个模型究竟在检测尖峰、异常片段、周期变化还是变量关系破坏。这个定义也是后续选择预测 重构 图网络或对比学习的依据。

$$X \in \mathbb{R}^{T \times C}, \quad S = (s_1, s_2, \dots, s_T), \quad s_t \in \mathbb{R}$$

式 1 多变量时序和逐时刻异常分数

T 是回看窗口长度， C 是变量数， s_t 是时刻 t 的异常分数。这里的输出是每个时刻一个分数，不是回归目标 y 的预测值。

4.3 Point-wise anomaly

$$|x_t - \hat{x}_t| > \delta, \quad \delta = \lambda G(x_t)$$

式 2 全局点异常的基本判据

x_t 是观测或实际值， $\hat{x}_t$ 是期望值或模型输出， δ 是阈值。论文写成 $\delta = \lambda G(x_t)$ ，用全局上下文方差调整阈值。直观上，偏离整体正常范围的尖峰被视为异常。

$$\delta \approx \lambda L(x_{t-k} : x_{t+k})$$

式 3 局部上下文阈值

局部点异常的异常性取决于 t 前后 k 个时刻。相同的压力值在白天可能正常，在夜间可能异常，因此属于 contextual anomaly。

4.4 Pattern-wise anomaly

$$\text{diss}(p, \hat{p}) > \delta, \quad \text{diss}(\tau, \hat{\tau}) > \delta, \quad \text{diss}(s, \hat{s}) > \delta$$

式 4 形状 趋势 周期异常的统一表达

p 表示子序列形状， τ 表示趋势， s 表示周期模式，带帽变量是正常期望模式，diss 是差异函数。该类需要一段时间数据，不能由单时刻决定。

4.5 Inter-metric anomaly

$$\text{diss}_{\text{corr}}(\text{corr}(x_i, x_j), \text{corr}(x_{t:t+k}^i, x_{t:t+k}^j)) > \delta$$

式 5 局部变量关系破坏

这类异常不是某个变量本身越界，而是 x_i 和 x_j 的正常相关关系在 t 到 $t+k$ 内发生变化。例如供水压力和流量分别都在历史范围内，但阀门状态对应的压力响应关系异常。它与用户定义的第③类学习外输入最直接对应。

4.6 时域和频域

$$X_k = \sum_{t=0}^{T-1} x_t e^{-i2\pi kt/T}, \quad k = 0, \dots, T-1$$

式 6 离散傅里叶变换

X_k 是频率 k 的复数幅值。FFT 可以把周期和频率变化显式化，适合 cycle anomaly。论文列出的 TimesNet D3R Dual-TF CATCH 使用或结合频域信息。

4.7 真正重要的结论

- 异常至少要沿时间和变量关系两条轴定义。
- point anomaly 不一定能代表真实系统的持续性异常。
- 局部 inter-metric anomaly 是本研究中最关键的组合关系变化。
- 论文给出的阈值公式主要是示意，并未形成统一可复现的阈值选择协议。

5 Taxonomy 精读

图 1 本综述的分类体系




图 1 本综述的一级分类和交叉标签

5.1 一级分类

$$a_t^{\text{forecast}} = \ell(x_t, \hat{x}_t), \quad a_t^{\text{recon}} = \ell(X_t, \hat{X}_t), \quad a_t^{\text{contrast}} = \text{diss}(z_t^{(1)}, z_t^{(2)})$$

式 7 三类 anomaly score 的统一理解 本报告归纳式

式 7 是本报告为便于比较而做的统一表达，不是论文原式。预测式比较未来观测和预测值，重构式比较输入和重构值，对比式比较两个视角或表示。

策略	基本假设	运行时需要	典型分数	是否依赖目标回归模型
预测式	正常历史可预测 异常导致预测残差增大	历史窗口和下一时刻实际值	prediction error 或 likelihood	通常训练独立预测器 不需要原目标回归模型内部信息
重构式	只学正常模式 异常难以重构	当前点或窗口	reconstruction error probability energy	可作为独立 input-only detector
对比学习式	正常样本多视图表征一致 异常产生差异	两个增强或表示分支	similarity dissimilarity density	通常为独立 detector 但需定义合理增强

5.2 学习范式

范式	论文说明	精读判断
Unsupervised	不依赖异常标签 并称训练只用正常数据	只用正常数据通常更接近 one-class 或 semi-supervised anomaly detection; 术语使用不够严谨
Semi-supervised	部分样本有标签 其余无标签	可能利用少量异常标签或正常标签, 原文描述语法含混
Self-supervised	由数据自身构造预测 遮蔽或增强任务	不需要人工标签, 但伪任务是否代表真实异常是关键

5.3 输入形式

论文区分 point input 与 window input。表 1 的 46 个模型中, LGMD、AD-LTI、DAGMM、LSTM-VAE 标为 point, 其他 42 个标为 window。作者认为近期方法更倾向窗口, 因为噪声 季节 趋势和持续异常无法从单点充分判断。

6 Forecasting Methods 精读

6.1 这一节在讲什么和作用

预测式方法用历史窗口预测下一时刻或未来片段, 实际值到达后用残差判断异常。该路线天然适合时序依赖, 也容易与现有 forecasting 模型衔接。

Backbone	代表方法	优势	限制	对末端压力场景
CNN TCN	DeepAnt TCN-ms TimesNet	并行 快速 局部和多尺度特征	普通 CNN 难捕捉很长依赖	适合短周期高频压力窗口
RNN	LSTM-NDT LGMD THOC AD-LTI	顺序建模 长期依赖	长序列慢 记忆和扩展性受限	适合中等长度历史和在线残差
GNN	MTAD-GAT GDN FuSAGNet DVGCRN DyGraphAD	显式变量或传感器依赖	图构造难 高维成本高	配水管网有拓扑时最具吸引力
Transformer	MAD CLFormer AnomalyBERT	长程依赖和并行	训练资源高 可能忽略局部细节	适合多模式长窗口 但需实时性验证

6.2 关键问题

- 预测式检测必须等实际 x_t 到达后才能计算当前残差, 因此不能在控制动作前单靠该分数判断当前输入是否安全。
- 若预测模型本身在异常上也能准确预测, 残差可能不大; 若正常状态不可预测, 误报会增加。
- 误差来自输入 OOD、concept shift、噪声和模型能力不足, 残差无法自动区分原因。
- 论文没有汇总各方法的窗口长度 阈值 运行时和统一评价结果, 必须回原论文核实。

7 Reconstruction Methods 精读

7.1 这一节在讲什么和作用

重构式方法只用正常或主要为正常的数据学习低维表示, 再还原输入。无法重构的点或窗口得到较高异常分数。作者按 AE VAE GAN Transformer Diffusion 介绍 22 个模型, 是全文最大方法族。

家族	代表方法	主要长处	主要短处	对应学习外
AE	DAGMM MSCRED USAD NPSR	结构直观 可输入侧独立检测	强模型也可能重构异常 误差难解释	①②③均可能 取决于训练覆盖
VAE	LSTM-VAE OmniAnomaly InterFusion SLA-VAE LARA	概率建模 可输出 reconstruct on probability	分布假设和 posterior collapse	低密度与不确定区域

家族	代表方法	主要长处	主要短处	对应学习外
GAN	MAD-GAN TadGAN MIM-GAN DAEMON DCGAN	学习复杂正常分布	训练不稳定 mode collapse	分布外和异常片段
Transformer	TransAnomaly Anomaly Transformer TranAD MEMTO	长程关系和 association modeling	复杂 资源高 阈值仍需调	时间和变量组合异常
Diffusion	DiffusionAE D3R	对噪声 缺失和多类型异常较稳健	训练 推理成本高	污染和缺失条件下的异常

7.2 真正重要的结论

- 重构式最接近独立的输入侧学习外检测器，因为不需要目标回归模型输出。
- 但 anomaly 与 reconstruction error 不是必然等价，表达能力过强时会把异常也重构得很好。
- 概率模型更适合表达低密度，但 Gaussian 假设或 posterior 校准会影响结论。
- 对社会基础设施，应优先检查异常分数能否定位到具体传感器和物理关系。

8 Contrastive Methods 精读

8.1 这一节在讲什么和作用

对比学习从同一正常窗口构造两个视角，要求其表示相近，并让不相似样本分离。作者按 LLM、MLP-Mixer 和 Transformer 整理 9 个模型。

结构	代表方法	优势	风险
LLM	AnomalyLLM aLLM4TS	few-shot 和外部语义知识	直接用于数值时序效果不稳定 需要 prompt 或微调 可能产生幻觉
MLP-Mixer	PatchAD	轻量 易并行	极复杂分布表达有限
Transformer	TRL-CPC RESIST DCdetector SimAD RESTAD	能结合长窗口 多视图和密度	增强策略可能定义了想检测的异常而非真实异常

8.2 与本研究的关系

对比学习适合没有异常标签的情况，但必须决定正负样本和数据增强。对于配水系统，随机打乱变量 缩放压力或切断时间片可能违反物理规律，若增强设计不合理，模型学到的是人工规则而不是实际学习外状态。

9 数据集精读

9.1 论文表 2 的含义

作者整理 source type、样本数、entity 数、维度、异常率和领域，但没有统一列出时间粒度 输入输出项 训练测试划分 标签定义 许可证或下载步骤。表内还混入 Ionosphere、Arrhythmia、Creditcard 等非典型时间序列或分类型数据，说明表 2 更像广义异常 benchmark 汇总，而不是严格 MTSAD 数据集清单。

Dataset	R S	Samples	Entities	Dims	Rate percent	Domain
MSL	Real	132046	27	55	10.48	Aerospace
NASA Shuttle Valve	Real	49097	1	9	7.0	Aerospace
Ionosphere	Real	351	-	33	36.0	Astronomy
SWAN-SF	Real	355330	5	51	23.8	Astronomy
SMAP	Real	562800	55	25	12.83	Environmental
OPPORTUNITY	Real	36224	24	133	3.4	Environmental
GECCO	Real	138521	1	9	1.25	IoT
CICIDS	Real	170231	-	72	1.28	IoT
Kitsune	Real	3018973	9	115	17.0	Cybersecurity
HTTP KDD99	Real	567479	-	3	0.4	Cybersecurity
SMTP KDD99	Real	95156	-	3	0.03	Cybersecurity

Dataset	R S	Samples	Entities	Dims	Rate percent	Domain
NAB AdExchange	Real	9616	3	2	-	Business
Creditcard	Real	284807	1	29	0.17	Finance
Genesis	Real	16220	1	18	0.3	ICS
GHL	Synth	200001	48	22	0.4	ICS
SWaT	Real	946719	1	51	11.98	ICS
WADI	Real	957372	1	123	5.99	ICS
trimSyn	Synth	17680	1	35	2.34	ICS
MSDS	Real	292860	1	10	5.37	ICS
Arrhythmia	Real	452	1	274	15.0	Healthcare
MBA	Real	200000	8	2	0.14	Healthcare
Thyroid	Real	3772	-	6	2.5	Healthcare
SVDB	Real	230400	78	2	13.6	Healthcare
Daphnet	Real	32594	35	3	13.2	Healthcare
Callt2	Real	10080	2	2	4.1	Infrastructure
Metro	Real	48204	1	5	0.1	Infrastructure
NYC	Real	17520	-	3	0.57	Infrastructure
Occupancy	Real	6208	2	8	28.7	Infrastructure
Exathlon	Real	47530	39	45	18.3	Server
PSM	Real	132480	1	25	27.76	Server
SMD	Real	1416825	28	38	4.16	Server

9.2 与社会基础设施最相关的数据集

Dataset	入出力 and 粒度	划分和标签	许可与下载	精读判断
SWaT	51 个传感器与执行器 1秒级 水处理过程	官方当前说明 7天正常 4天攻击 逐时标签; 41次攻击的版本说明	iTrust 表单申请 免费 需遵守数据使用协议	标签是攻击或异常行为 不是回归模型 OOD; 非常适合水务故障攻击 benchmark
WADI	123 个传感器与执行器 约1秒级 水分配试验台	通常 14天正常 2天攻击 约15个攻击片段	iTrust 表单申请 版本和条款需固定	比 SWaT 更接近配水管网 但仍是试验台攻击标签
SMD	28 台服务器 每台38指标 1分钟级 5周	前半训练 后半测试 测试有逐点标签	OmniAnomaly GitHub 公开 仓库许可需单独确认	结构清楚 但与水务物理关系较远
SMAP MSL	NASA 遥测 多通道 MSL 文中称每分钟	训练段正常 测试段含专家或事件标签 具体通道和划分需看原始发布	NASA Telemanom 相关资源 具体再利用条款需核对	适合遥测异常 不等于输入适用域
Metro NYC Callt2	论文仅给样本数 维度 异常率	原文未说明统一划分和标签定义	下载和许可未整理	信息不足 不能直接作为候选数据集立项依据

9.3 学习内外正解标签的本质差异

- 综述数据集的标签通常是攻击 故障 医疗事件或人工异常区间。
- 目标回归模型的 OOD 标签应该依据该模型的训练分布 训练密度或变量关系定义。
- 某段 SWaT attack 对系统异常检测是真阳性，但若目标回归模型训练时包含相同攻击模式，它未必是该模型的 OOD。
- 相反，一个新的正常运行模式可能没有 attack 标签，但对旧回归模型属于 OOD。

10 应用领域

领域	论文中的主要内容	与本研究的价值
ICS	SWaT WADI 水处理和配水 攻击检测 轻量模型 XAI	最直接的社会基础设施对应
Infrastructure	隧道 RADIM 高频交通传感器	强调实时 多维子序列和高频计算
Server monitoring	SMD PSM Exathlon 微软服务	适合验证高维和实时报警 但物理规律弱
Aerospace	MSL 航天器遥测 阀门数据	适合强安全要求和延迟故障标签
Environmental	SMAP 环境和土壤水分	适合季节性和空间差异
Healthcare Finance Cybersecurity	ECG 交易 网络攻击	提供不平衡和事件评价经验 领域含义不可直接迁移

11 Future Direction 精读

作者提出的方向	内容	精读评价
Discrepancy	通过正负对和表征差异增强异常分离	需解决增强策略是否符合真实物理异常
Domain knowledge	结合统计 频域和领域知识	对水务最重要 可加入拓扑 水力平衡和控制规则
Benchmark and metrics	更真实的数据 明确训练测试划分 直观可解释且少调参的指标	作者没有具体讨论 point adjustment 事件级指标和告警成本
LLM techniques	利用少样本 多模态和文本知识	数值时序收益尚不稳定 成本 幻觉和数据治理是关键

12 综述质量的批判性分析

方面	优点	不足
范围	覆盖 46 个 2018 到 2024 前后的深度模型	无检索协议 不能判断遗漏和选择偏差
分类	把判定策略和 backbone 输入形式结合	预测 重构 对比并非完全互斥 多个模型是混合型
异常定义	新增 temporal 与 inter-metric 层次	若干公式为概念示意 变量和 diss 定义不充分
数据集	31 个数据集跨 10 类领域	列信息缺少粒度 划分 标签定义 许可 下载; 混入非典型 MTS
比较	每一方法族给出定性 pros cons	没有统一实验 性能表 计算量 实时性 阈值或统计显著性
准确性	提供大量原文论入口	存在术语和描述问题 如 unsupervised 定义 DeepAnt 描述和表内拼写

12.1 需要回原论文核实的内容

- 作者把 DeepAnt 放在 forecasting 类，但正文称其使用 reconstruction error；原始方法通常以预测误差为核心，存在表述不一致。
- 表 1 的 Bonkbone 拼写错误以及个别方法名 引用编号对齐问题提示需要逐篇核验。
- 表 2 的部分数据集不是严格多变量时序或列存在空缺，不能照表直接用于实验。
- 综述没有集中整理阈值规则和评价指标，因此不能据此比较检测率与误检率。

13 与学习外入力データ研究的关系

本研究定义	综述中的对应	覆盖情况
①训练输入分布或范围外	global point anomaly 低 likelihood 大预测或重构误差	多种方法可覆盖 但系统异常与模型 OOD 需重新定义
②训练稀少且学习不足区域	density likelihood VAE RBF representation distance	综述未单独建立该标签 可由低密度方法近似
③单项范围内但组合或相关关系变化	global local temporal-local inter-metric anomaly GNN 和 correlation modeling	这是本文对本课题最有价值的部分
分布随时间变化	trend cycle pattern anomaly window methods	可监视持续 drift 但多数方法不区分新正常模式和故障

13.1 输入数据だけで検知できるか

方法族	只用运行输入吗	需要目标 AI 内部或输出吗	检测时点
预测式 MTSAD	训练独立预测器后使用输入和随后实际值	通常不访问目标 AI 但需要独立 predictor 输出	实际下一时刻到达后
重构式 MTSAD	是 当前输入点或窗口即可	不需要目标 AI 内部信息	输入到达后立即
对比学习式 MTSAD	是 但需要两个表示视图	不需要目标 AI 但需要 detector encoder	输入窗口到达后
OMPb	当前 y 不要 但输入需进入目标 backbone 和 Bayesian head	需要目标模型输出和 posterior	预测前可计算 certificate
山原 AD	是 单时刻多变量向量	不需要目标 AI 内部或输出	推定前立即

14 与 OMPb 和山原论文的联系

比较项	S6 综述中的 MTSAD	OMPb	山原论文
目标	检测系统数据异常	监视 shift 并在线校准 forecasting	判断压力回归模型适用域
一级逻辑	预测 重构 对比	posterior disagreement 加 certificate	范围 中心距离 kNN 密度
输入	主要为时间窗口 42 46	24 或 96 时刻窗口	单时刻多变量
标签	攻击 故障 异常区间	source target domain 和预测误差	推定误差阈值的假定真值
目标模型依赖	通常独立 detector	依赖 backbone Bayesian head	独立 input-only
关键关系	inter-metric anomaly	预测分歧反映 task-related shift	Mahalanobis 处理变量相关性

15 社会基础设施监视控制的适用建议

1. 单时刻入口层使用山原式 minMax 与 kNN Mahalanobis，立即检查越界 低密度和变量组合异常。
2. 时间窗口层使用重构式或 GNN 异常检测，检查趋势 周期 持续片段和跨传感器关系。配水拓扑明确时优先验证 GDN 或 MTAD-GAT 类图模型。
3. 预测可信度层使用 OMPb 或 ensemble uncertainty，只关注与目标回归输出相关的 shift，并在真实压力到达后保守校准。
4. 原因诊断层结合传感器质量规则 水力平衡 设备操作记录和 attack log，区分传感器故障 新运行模式和网络攻击。
5. 安全动作层使用分级告警，不让单一 anomaly score 直接触发危险控制。记录误报率 事件检出率 检测延迟和 fallback 结果。

16 本篇结论

- 文献价值评级：作为方法地图高，作为定量比较依据中低。
- 与本课题最相关的概念：local inter-metric anomaly、window input、forecast reconstruction contrast 三类分数。
- 最值得继续精读的方法：MTAD-GAT、GDN、MSCRED、USAD、OmniAnomaly、InterFusion、Anomaly Transformer、TranAD、DCdetector。
- 最值得优先验证的数据集：WADI 和 SWaT；但它们的异常真值是攻击或故障，不是目标回归模型 OOD。
- 最终总报告不能直接复制该综述的优缺点排名，必须回到原始论文核实输入 数据划分 阈值 指标和实时性。

第二部分 日本語研究レポート

1 文献情報

項目	内容
論文名	A Survey of Deep Anomaly Detection in Multivariate Time Series Taxonomy Applications and Directions
著者	Fengling Wang Yiyue Jiang Rongjie Zhang Aimin Wei Jingming Xie Xiongwen Pang
発表年	2025年
発表先	Sensors 25 1 190
DOI	10.3390 s25010190
License	CC BY 4.0

2 研究目的と主要結論

本論文は、深層学習による多変量時系列異常検知を、異常種類、学習パラダイム、モデル構造、入力形式、時空間および時周波数の観点から整理した review article である。表 1 では 46 手法を forecasting 15、reconstruction 22、contrastive 9 に分類し、表 2 では 31 dataset を整理している。

本調査テーマに対して特に有用なのは、temporal anomaly と inter-metric anomaly の区別である。local inter-metric anomaly は、各入力項目が学習時範囲内でも、項目間の組合せや相関関係が変化する学習外入力に直接対応する。

3 異常の定義

分類	定義	学習外入力との対応
Global point	全系列に対して単一点が大きく逸脱	入力範囲外に対応しやすい
Local point	局所 window の文脈に対して逸脱	時間帯や運転モード依存の contextual anomaly
Shapelet Trend Cycle	部分系列の形状 傾向 周期が正常 pattern と異なる	複数時刻入力が必要とする collective anomaly
Global inter-metric	系列全体で変数間関係が変化	長期的な運転状態変化
Local inter-metric	局所区間で変数相関が破壊	学習外定義③に最も近い
Temporal-local inter-metric	時間 pattern と変数関係を同時に破壊	複合的な未学習状態

4 手法分類

方式	判定アルゴリズム	必要情報	長所	短所
Forecasting	実測値と予測値の誤差を anomaly score とする	履歴窓 predictor output 後着する実測値	時間依存を扱いやすい	実測値到着前に当該時点を判定できない
Reconstruction	入力と再構成値の差または確率を用いる	現在の入力点または window と独立 detector	input-only で運用可能	高表現モデルが異常も再構成する可能性
Contrastive	二つの view の表現類似度または差異を用いる	入力 window augmentation encoder	ラベル不要で微妙な差を強調	正負ペア設計が結果を支配

5 学習パラダイムと入力形式

- Unsupervised、semi-supervised、self-supervised を区別しているが、論文の unsupervised 定義は normal-only training と混在しており、原著確認が必要である。
- 表 1 では 46 手法中 42 手法が window input、4 手法が point input と整理される。
- 単一時刻に直接適用可能な候補は LGMD、AD-LTI、DAGMM、LSTM-VAE であるが、実際の内部処理と評価単位は原著で再確認する必要がある。

6 Dataset

Dataset	Survey 記載	正解ラベル	利用条件と判断
SWaT	946719 samples 51 dims anomaly rate 11.98 percent	normal attack の時刻ラベル	iTrust へ利用申請 水処理 ICS として有用
WADI	957372 samples 123 dims anomaly rate 5.99 percent	normal attack interval	iTrust へ利用申請 配水システムに最も近い
SMD	1416825 samples 28 entities 38 dims 4.16 percent	test point label	GitHub から取得可能 server metric で物理系とは異なる
SMAP MSL	562800 132046 samples	telemetry anomaly interval	NASA 系 遥測異常に適する
Metro NYC Callt2	Infrastructure と分類	本文の定義が不足	time granularity split license を原著確認

Survey は dataset の入力項目、時間粒度、train test split、label definition、license、download 手順を統一的に示していない。このため表 2 は候補抽出に使用し、実験計画には各 dataset の原著と公式配布条件を使用する。

7 評価方法と閾値

本論文は review であり、46 手法を同一条件で再評価していない。AUROC、AUPR、precision、recall、F1、false alarm rate、detection delay の横断比較表はなく、閾値決定方法も体系化されていない。式 4 と式 5 の δ は概念例であり、実装可能な共通閾値ではない。

社会インフラでは point-level metric だけでなく、event-level recall、1日当たり誤警報数、検知遅延、連続異常区間の検出、運転判断への影響を評価すべきである。point adjustment を用いる場合は性能が過大評価される可能性があるため、適用有無を明示する。

8 長所と短所

長所	短所
異常種類と方法分類を一つの論文で確認できる	systematic review の検索式と選定基準がない
46 手法を input code backbone 等で比較	性能 計算量 window size threshold の統一比較がない
31 dataset と 10 application domain を整理	粒度 split label license download 情報が不足
inter-metric anomaly を明示	原因が sensor fault attack new regime のどれかは識別しない
将来方向として domain knowledge と benchmark を強調	LLM の利点を強く述べる一方で実証比較はない

9 山原論文および OMPB との関係

山原論文は、単一時刻の配水入力に対して minMax、training center distance、kNN density を使い、対象回帰モデルの applicability domain を直接判定する。一方、本 survey の MTSAD は主に window を用いてシステム異常を検知するため、対象回帰モデルの適用可能性とは評価対象が異なる。

OMPB は target backbone と Bayesian head の posterior disagreement を利用する model-aware 手法である。本 survey の forecasting reconstruction contrastive のうち、OMPB は forecasting と uncertainty disagreement を組み合わせた別系統の複合手法と位置付けられる。

10 社会インフラ適用可能性

1. 山原式 kNN Mahalanobis を単一時刻の input-only AD として使用する。
2. reconstruction または GNN MTSAD を window-based system anomaly layer として追加する。
3. OMPB を対象回帰モデルに関係する uncertainty と online calibration layer として使用する。
4. センサ品質、物理整合性、操作履歴、攻撃情報を原因診断に併用する。
5. binary threshold は正常 validation data の分位点と許容誤警報数から決め、event-level backtest を行う。

11 結論

本 survey は、MTSAD の method map として有用であり、特に inter-metric anomaly と window-based detector の整理は本調査に直接貢献する。ただし、各手法の性能順位、real-time 性、閾値、dataset license を決定する根拠としては不十分である。最終研究報告では、この survey を入口として MTAD-GAT、GDN、MSCRED、USAD、OmniAnomaly、Anomaly Transformer、TranAD などの原著を個別に精読する必要がある。

第三部分 日本語口頭説明原稿

8分から12分の説明

今日は、Wang らの A Survey of Deep Anomaly Detection in Multivariate Time Series について報告します。Sensors に 2025 年に掲載された review article で、深層学習による多変量時系列異常検知、MTSAD を整理した論文です。

最初に結論を述べます。この論文の価値は、個別手法の性能順位ではなく、異常の種類と方法の全体地図を把握できる点にあります。作者は 46 手法を forecasting、reconstruction、contrastive の三つに分類し、31 の公開 dataset を整理しています。

MTSAD では、時間方向の依存と変数間の依存を同時に考える必要があります。作者は temporal anomaly と inter-metric anomaly を区別します。temporal anomaly には global point、local point、shapelet、trend、cycle anomaly があります。inter-metric anomaly には global、local、temporal-local があり、変数間の正常な関係が崩れる状態を表します。

本調査テーマで最も重要なのは local inter-metric anomaly です。これは、各入力項目が学習時の範囲内でも、圧力と流量、弁開度と圧力などの組合せや相関が異なる状態に対応します。従って、単純な minMax では検出できない学習外入力を表現できます。

一つ目の forecasting method は、過去 window から次の値を予測し、実測値との誤差を anomaly score にします。CNN、RNN、GNN、Transformer が使われます。特に GNN はセンサ間関係を graph として表現できるため、配水管網に適しています。ただし実測値が到着するまで誤差を計算できないため、現在の制御判断前に完全な判定はできません。

二つ目の reconstruction method は、正常 data から入力を再構成し、再構成誤差または確率を anomaly score にします。AE、VAE、GAN、Transformer、Diffusion が含まれます。この方式は対象回帰モデルの内部情報を必要とせず、input-only detector として利用できます。ただし高性能な autoencoder が異常も再構成すると、見逃しが発生します。

三つ目の contrastive method は、同じ window の二つの view の表現を比較します。LLM、MLP-Mixer、Transformer 系が紹介されています。ラベルを必要としない利点がありますが、正例 負例や data augmentation の設計が結果を大きく左右します。水務 data に非物理的な augmentation を行うと、実際の異常ではなく人工的な変換を学習する危険があります。

入力形式について、表 1 では 46 手法中 42 手法が window input、4 手法だけが point input です。従って、最近の MTSAD は複数時刻を一度に入力する設計が中心です。山原論文のような単一時刻入力とは明確に区別する必要があります。

dataset では SWaT と WADI が重要です。SWaT は水処理設備の 51 センサと actuator、WADI は配水設備の 123 センサと actuator を含みます。どちらも正常期間と attack 期間のラベルがあります。しかし、その正解ラベルは system attack であり、対象回帰モデルの training distribution に対する ID OOD label ではありません。

この survey の限界もあります。文献検索 database、検索式、対象期間、採用除外基準がなく、systematic review ではありません。また 46 手法を同じ条件で再実験しておらず、AUROC、F1、false alarm、計算時間、window size、threshold を横断比較できません。dataset 表にも時間粒度、split、license、download 条件が不足しています。

山原論文との関係では、山原法は単一時刻 input に対する model-independent applicability domain です。この survey は主に window-based system anomaly detection です。OMPB は target model の posterior disagreement を用いる model-aware calibration です。従って三者は競合ではなく、山原法を単時刻 AD、MTSAD を時間関係とセンサ関係の監視、OMPB を予測不確実性と online calibration に用いる階層構成が考えられます。以上です。

想定質問と回答

質問	回答要点
この survey の新規性は何ですか	temporal と inter-metric anomaly の分類、および forecasting reconstruction contrastive と複数の交差軸による整理です
一番適した方法はどれですか	survey は共通実験をしていないため順位は決められません。入力単位、ラベル、遅延、graph、実時間制約から選びます
単一時刻でも使えますか	表 1 では 4 手法が point input ですが、多くは window です。末端圧力では山原式 AD の方が直接的です
入力だけで検知できますか	reconstruction と contrastive は可能です。forecasting は次時刻実測値、OMPB は target model prediction を必要とします
SWaT WADI の OOD label は使えますか	attack label としては使えますが、回帰モデルの学習外 label と同一ではありません
新運転状態と sensor fault を区別できますか	anomaly score だけでは困難です。物理ルール、複数センサ整合、操作履歴、継続時間を併用します

附录 方法标准化一览

方法族	代表手法	输入	训练标签	运行信息	适合检测	主要风险
Forecast CNN	DeepAnt TCN-ms TimesNet	Window	Normal-only or mixed	历史窗 实际下一点	点异常 周期 预测残差	输出延迟 长依赖
Forecast RNN	LSTM-NDT LGMAD THOC AD-LTI	Point or Window	Un Semi Self	历史状态 实际值	趋势 多尺度局部异常	序列计算慢
Forecast GNN	MTAD-GAT GDN DVGCRN	Window	Un Self	历史窗 图 之后 实测值	inter-metric 时空异常	图错误 计算量
Forecast Transformer	MAD CLFormer AnomalyBERT	Window	Un Self	历史窗 实际值	长依赖 上下文异常	资源和阈值
AE	DAGMM MSCRED USAD NPSR	Point or Window	Un Semi	当前输入	分布外 重构异常	异常也能重构
VAE	OmniAnomaly InterFusion LARA	Window	Un Semi	当前输入 概率模型	低密度 时序和变量依赖	分布假设 posterior
GAN	MAD-GAN TadGAN DAEMON	Window	Un	当前输入 生成器 判别器	复杂分布 异常片段	训练不稳定
Diffusion	DiffusionAE D3R	Window	Un	当前输入 多步去噪	噪声 缺失 异常片段	训练推理昂贵
Contrastive	DCdetector SimAD RESTAD PatchAD	Window	Un Self	两个 view encoder	微妙表征差异	增强定义偏差

参考文献

- [1] Wang F et al. A Survey of Deep Anomaly Detection in Multivariate Time Series Taxonomy Applications and Directions. Sensors 2025 25 190. <https://doi.org/10.3390/s25010190>
- [2] 山原裕之ほか. 配水管網における圧力推定のための機械学習モデルの適用領域の検討.
- [3] Huang C et al. Model-Agnostic Online Certificate-Driven Calibration for Time Series Forecasting Under Distribution Shift. UAI 2026.
- [4] iTrust Secure Water Treatment Dataset. <https://www.sutd.edu.sg/itrust/itrust-labs/datasets/dataset-characteristics/swat/>
- [5] iTrust Water Distribution Dataset. <https://www.sutd.edu.sg/itrust/>
- [6] Su Y et al. Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network. KDD 2019.