

文献レビュー

社会インフラ向け AI における非画像・ 数値時系列データの分布外検知

2026 年 8 月 16 日

要旨

本報告は、社会インフラの監視制御で用いられる非画像の数値時系列データのみを対象とする。代表例は、温度、圧力、流量、電圧、バルブ開度、振動、サーバ KPI、宇宙機テレメトリなどである。画像、映像、文章、音声の OOD データセットは評価対象外とする。

この領域の OOD 検知は、数値時系列窓が正常運転データ、または時系列モデルの既知クラスで十分に表現されているかを判定する問題である。正常データの場合のみは、統計的プロセス監視、変化検知、一クラス学習、予測残差、再構成モデルが中心となる。既存の数値時系列分類器がある場合は、その時間特徴に距離・密度モデルを追加できる。最近の時系列研究では、画像分類器向け信頼度手法の直接転用より、深層特徴モデリングが有望である [1]。

推奨する公開データもすべて数値時系列である。Tennessee Eastman Process (TEP)、NASA SMAP/MSL、Server Machine Dataset (SMD)、SWaT/WADI、および UEA 多変量アーカイブの数値センサ subset を候補とする。初期候補は、PCA の Hotelling T2 と SPE/Q、Mahalanobis 距離、窓特徴上の Isolation Forest または One-Class SVM、予測・再構成 baseline、時間特徴モデリングである。具体的な実験範囲はインターン期間中の担当業務と利用可能なデータに応じて決定する。

1. 対象範囲と問題設定

数値入力窓を $X_t = [x_{t-L+1}, \dots, x_t] \in \mathbb{R}^{L \times d}$ とする。L は窓長、d はセンサまたは制御チャンネル数である。検知器はスコア $s(X_t)$ を出力し、独立 calibration set で決めた閾値 τ を超えた場合に棄却または警報を行う。

対象は以下である。

- 産業・インフラ設備の多変量センサおよびアクチュエータ系列；
- 宇宙機、サーバ、ネットワーク、電力、水道、交通、製造設備のテレメトリと KPI；
- 運転モード、イベント、故障種類を予測する数値時系列分類器；
- 異常ラベルが少ない正常データ中心の監視。

画像、映像、自然言語、音声の OOD 検知は対象外である。画像研究由来の手法は数値時間モデルへ直接適用できる場合のみ二次 baseline とし、中心的な候補とはしない。

2. 数値時系列における三つの設定

2.1 時系列分類器の semantic OOD

モデルは既知の運転モードや故障クラスだけを学習する。テスト窓が未知クラスの場合、時間 embedding、分類出力、クラス条件分布から予測を棄却する。同一数値データセット内でクラスを留保し、ID/OOD のセンサ、単位、サンプリング特性、系列長を一致させる評価が望ましい [1]。

2.2 運転条件 shift と concept drift

設備が物理的には有効でも、負荷、季節、制御設定、校正、劣化、環境が変わる。これは短い異常より持続的・漸進的な分布変化であり、change-point、drift statistics、適応 reference window、運転条件別 calibration が適する。

2.3 時系列異常検知

正常な時間ダイナミクスから外れる点または区間を検知する。正常データしかない場合に一般的であり、sample-level の棄却だけでなく event recall、検知遅延、時間当たり誤報数で評価する。

3. インフラ数値時系列の特徴

- チャンネル間相関： 各値が正常範囲でも、圧力・流量・バルブ・制御出力の関係が不整合となり得る。
- 時間依存： 異常は lag、微分、位相、周波数、状態遷移だけに現れる場合がある。
- 複数の正常状態： 起動、停止、保守、ピーク負荷、季節運転、安全な劣化状態を一律に OOD としない。
- 非定常性： 正常分布が変化し、固定閾値は警報過多を起こす。
- 欠損・非同期： センサ dropout、非同期 sampling、resampling がスコア分布を変える。
- 学習汚染： 正常アーカイブに小故障や未記録保守が含まれる場合がある。
- 運用コスト： 誤報、検知遅延、edge 計算量、説明性が小さな AUROC 差より重要な場合が多い。

4. 非画像・数値時系列向け手法

手法群	代表技術	数値時系列スコア	長所	制約	適用先
統計のプロ	PCA/DPCA、PLS、	主部分空間内の距	成熟、高速、解釈容	線形・定常仮	工場、水道、電

手法群	代表技術	数値時系列スコア	長所	制約	適用先
セス監視	Hotelling T2、SPE/Q [2-4]	離と残差エネルギー	易	定、運転状態分離が必要	力、多チャンネル制御
距離・robust covariance	Mahalanobis、robust covariance、クラス条件 Gaussian	ID 窓特徴または時間 embedding までの距離	透明、低 latency	高次元・多峰 ID で共分散推定が難しい	既存特徴または時系列分類器
ークラス・isolation	One-Class SVM、Isolation Forest、LOF、Deep SVDD [5]	境界、isolation depth、局所密度、超球距離	正常データのみで学習可能	scaling と特徴に敏感	設備 condition monitoring
逐次変化検知	CUSUM、EWMA、Page-Hinkley、change-point	参照過程からの累積偏差	小さな持続 shift と online に適合	reference stability と reset logic が必要	劣化、校正 drift、運転変化
予測残差	AR/ARIMA、state-space/Kalman、LSTM/TCN/Transformer	残差、標準化 innovation、予測尤度	時間動特性を直接表現	正常な regime change でも誤差増大	規則 sampling のテレメトリと制御
再構成	PCA、AE、VAE、USAD [6]	再構成誤差・確率	正常多変量データに自然	anomaly も再構成する可能性	IT、産業センサ、水処理
確率時間モデル	GMM、HMM、OmniAnomaly [7]、Flow	負対数尤度・尤度比	確率性と多状態を表現	raw likelihood と calibration に注意	反復 regime を持つテレメトリ
時間 association / attention	Anomaly Transformer [8]、TranAD [9]、MEMTO [10]	association discrepancy、再構成、潜在偏差	長期・変数間依存を表現	計算・調整コスト、評価法依存	高次元多変量テレメトリ
時間表現 + 特徴モデル	TS2Vec [11]、encoder + PCA/OCSVM/IF、DFM [1]	embedding 空間の距離・再構成誤差	表現と検知を分離	窓・augmentation・embedding stability に依存	数値系列 classifier の semantic OOD
時系列専用校正 OOD	SRS [12]、CODiT [13]	季節尤度比・conformal temporal equivariance	時間構造と誤報解釈	分解コスト、時間依存下の保証	周期系、安全校正が必要な系

4.1 統計 baseline は必須

PCA process monitoring は測定空間を主成分部分空間と残差部分空間に分ける。Hotelling T2 はモデル内部の変動、SPE/Q はモデルで説明できない残差を監視する [2-4]。Dynamic PCA は lag 変数や移動窓で serial dependence を扱う。計算量が小さく監査可能で、産業数値データとの整合性が高いため、deep model は必ずこれらと比較する。

4.2 窓特徴によるークラス検知

各数値窓から平均、標準偏差、傾き、RMS、微分 energy、周波数 power、自己相関、チャンネル間相関を抽出し、Mahalanobis、One-Class SVM、Isolation Forest を ID 窓だけで学習する。production AI の内部へアクセスできない場合や透明な edge 実装に適する。

4.3 予測・再構成

予測法は直近 history から説明できない将来値を検知する。state-space innovation は制御系で解釈しやすい。USAD は adversarial autoencoder [6]、OmniAnomaly は stochastic recurrent model と reconstruction probability [7] を用いる。強いモデルが異常も再構成する over-generalization が主なリスクである。

4.4 時間深層モデルと特徴検知

Anomaly Transformer は時間 association の差 [8]、TranAD は Transformer、self-conditioning、adversarial training [9]、MEMTO は memory と input/latent deviation [10] を用いる。TS2Vec は multiscale temporal representation を学習し、軽量なークラス検知器へ接続できる [11]。

TS-OOD の数値多変量実験では、一般的な confidence post-hoc 法は不安定で、PCA やークラス法による deep-feature modeling がより有望であった [1]。したがって、時間 embedding と透明な detector を、画像向け activation clipping 等より優先する。

5. 数値公開データセット

優先度	データ	数値チャンネル・領域	推奨用途	アクセス・注意
A	Tennessee Eastman Process [14]	化学プロセス測定・操作変数、既知故障	産業 fault/OOD、運転状態、channel attribution	公開；synthetic であり現実一般化は別検証
A	SMAP/MSL [15]	NASA 宇宙機テレメトリと異常区間	テレメトリ異常、遅延、チャンネル評価	公開；前処理と label version を統一

優先度	データ	数値チャネル・領域	推奨用途	アクセス・注意
A	SMD [7]	28 server の 38 次元 KPI	infrastructure monitoring、機器間 robustness	公開；transfer 以外は機器別 model
A	UEA 数値多変量 subset [1,16]	センサ、motion、EEG/ECG、traffic 等	同一 source の class-held-out semantic OOD	公開；画像・映像由来 task を除外
B	SWaT / WADI [17]	水処理・配水センサ、actuator、attack	cyber-physical / process validation	申請制、再配布禁止
B	TSB-AD [18]	数値時系列 anomaly の大規模 collection	metric stress test	公開；主に TSAD
B	MTAD [19]	公開 multivariate KPI と統一 toolkit	accuracy、efficiency、delay、salience	公開；前処理 version 固定
C	UCR Anomaly Archive [20]	単変量数値系列	metric・threshold sanity check	公開；多変量制御の現実性は限定的

万能な単一データセットはない。semantic OOD には UEA 数値 class-held-out、産業 fault には TEP、実テレメトリには SMAP/MSL または SMD、許可取得後に SWaT/WADI を組み合わせる。画像データセットは不要である。

6. 数値時系列の評価方法

6.1 分割と校正

1. 重複窓作成前にクラス、機器、運転状態、物理 event、時間 block で分割する。
2. 同一 event の隣接窓を一つの split に置き、temporal leakage を防ぐ。
3. 正常のみの detector は ID training data だけで学習する。
4. 独立 ID calibration 期間で閾値を決め、final OOD label で調整しない。
5. near/far OOD、gradual drift、急な sensor fault、正規 regime change を分ける。
6. 複数 machine、class split、期間、random seed で報告する。

6.2 指標

- AUROC、AUPR-OOD；
- FPR95、時間・日当たり誤報数；

- event recall、time-to-detect、検知遅延；
- ID task accuracy または forecast error；
- inference latency、memory、retraining time；
- 季節・負荷・機器・保守期間を跨ぐ threshold stability；
- fault localization が必要な場合の variable attribution accuracy。

point-adjusted F1 のみを報告してはならない。point adjustment は結果と手法順位を大きく水増しする可能性がある [21]。未調整 point metric、event metric、delay metric、および必要に応じ VUS-PR を併記する [18,21]。

7. 今後の評価候補案

以下は候補であり、固定された実験計画ではない。具体的な範囲、データ、手法はインターン期間中の担当業務、データアクセス、実装時間に応じて選択する。

候補経路	手法	適用データ	目的
透明 process baseline	PCA/DPCA の T2・SPE/Q、robust Mahalanobis	TEP、SWaT/WADI	解釈可能な産業 baseline
model-independent window	窓特徴 + Isolation Forest / One-Class SVM	SMD、SMAP/MSL、TEP	AI model を変更しない正常-only OOD
時間予測	state-space/Kalman または小型 TCN/LSTM	規則テレメトリ・制御	dynamic inconsistency と channel residual
再構成	PCA または小型 AE/USAD	多変量 sensor window	線形・非線形 normal learning 比較
数値 semantic OOD	1-D temporal encoder + Mahalanobis / DFM-PCA/OCSVM	UEA 数値 subset	同一 sensor の未知 sequence class
校正 alarm	quantile または blocked conformal threshold	選定インフラデータ	threshold と false alarm の関係

今後の候補として、多チャネル数値センサ窓から時間・チャネル間特徴を抽出し、ID データのみで PCA 部分空間を学習して、保留した ID データで閾値を校正する透明な pipeline が考えられる。

8. 配備上の提案

産業プロセス・公共設備

運転状態別 PCA/DPCA、T2、SPE/Q、contribution analysis から始める。起動、停止、保守、負荷帯を必要に応じ正常 regime として分ける。statistical baseline と threshold behavior を確認してから nonlinear/deep model を追加する。

テレメトリ・IT インフラ

cross-entity transfer が目的でなければ machine/entity 別に model を作る。forecast residual、小型 AE、window-feature one-class が実用的な開始点である。欠損率と sampling change は別の data-quality signal として監視する。

数値時系列 classifier

運転状態や故障を数値系列から分類する model では、出力直前の temporal embedding に Mahalanobis、PCA reconstruction、One-Class SVM、Isolation Forest を適合する。Energy/softmax は二次 baseline に限定する。

安全・制御統合

OOD は abstention、operator review、定義済み safe fallback の trigger とする。process constraint と safety validation なしに直接 control action を変更しない。hysteresis と minimum duration が加える delay を報告する。

9. 結論

本報告は、非画像の数値時系列データを対象とする。中心となるのは、統計的プロセス監視、クラス・isolation、逐次変化検知、予測残差、再構成・確率時間モデル、時間表現と特徴空間検知である。画像 OOD benchmark と画像専用 activation 手法は提案評価に含めない。

今後の候補として、PCA/DPCA の T2・SPE/Q、robust Mahalanobis、窓特徴の Isolation Forest / One-Class SVM、小型予測・再構成 model、既存数値系列 classifier の deep-feature modeling が

考えられる。これらは固定実験ではない。具体的な範囲はインターン期間中の担当業務、利用可能な数値データ、real-time 要件、実装時間に応じて決定する。

参考文献

- [1] Gungor, O., Rios, A. S., Ahuja, N., & Rosing, T. (2025). *TS-OOD: Evaluating Time-Series Out-of-Distribution Detection and Prospective Directions for Progress*. arXiv:2502.15901. <https://arxiv.org/abs/2502.15901>
- [2] Qin, S. J. (2003). *Statistical Process Monitoring: Basics and Beyond*. Journal of Chemometrics, 17(8-9), 480-502. <https://doi.org/10.1002/cem.800>
- [3] Choi, S. W., Lee, C., Lee, J.-M., Park, J. H., & Lee, I.-B. (2005). *Fault Detection and Identification of Nonlinear Processes Based on Kernel PCA*. Chemometrics and Intelligent Laboratory Systems. <https://doi.org/10.1016/j.chemolab.2004.05.001>
- [4] Lee, J.-M., Yoo, C., Choi, S. W., Vanrolleghem, P. A., & Lee, I.-B. (2004). *Nonlinear Process Monitoring Using Kernel Principal Component Analysis*. Chemical Engineering Science, 59(1), 223-234. <https://doi.org/10.1016/j.ces.2003.09.012>
- [5] Ruff, L., et al. (2018). *Deep One-Class Classification*. ICML, PMLR 80, 4393-4402. <https://proceedings.mlr.press/v80/ruff18a.html>
- [6] Audibert, J., et al. (2020). *USAD: UnSupervised Anomaly Detection on Multivariate Time Series*. KDD. <https://doi.org/10.1145/3394486.3403392>
- [7] Su, Y., et al. (2019). *Robust Anomaly Detection for Multivariate Time Series through Stochastic Recurrent Neural Network*. KDD. <https://doi.org/10.1145/3292500.3330672>
- [8] Xu, J., Wu, H., Wang, J., & Long, M. (2022). *Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy*. ICLR. https://openreview.net/forum?id=LzQQ89U1qm_
- [9] Tuli, S., Casale, G., & Jennings, N. R. (2022). *TranAD: Deep Transformer Networks for Anomaly Detection in Multivariate Time Series Data*. PVLDB, 15(6), 1201-1214. <https://doi.org/10.14778/3514061.3514067>
- [10] Song, J., Kim, K., Oh, J., & Cho, S. (2023). *MEMTO: Memory-guided Transformer for Multivariate Time Series Anomaly Detection*. NeurIPS 36. https://proceedings.neurips.cc/paper_files/paper/2023/hash/b4c898eb1fb556b8d871f9e9ead92256-Abstract.html
- [11] Yue, Z., et al. (2022). *TS2Vec: Towards Universal Representation of Time Series*. AAAI 36(8), 8980-8987. <https://doi.org/10.1609/aaai.v36i8.20881>
- [12] Belkhouja, T., Yan, Y., & Doppa, J. R. (2024). *Out-of-Distribution Detection in Time-Series Domain: A Novel Seasonal Ratio Scoring Approach*. ACM TIST, 15(1). <https://doi.org/10.1145/3630633>
- [13] Kaur, R., et al. (2022). *CODiT: Conformal Out-of-Distribution Detection in Time-Series Data*. arXiv:2207.11769. <https://arxiv.org/abs/2207.11769>
- [14] Rieth, C. A., et al. (2017). *Tennessee Eastman Process Simulation Data*. Harvard Dataverse. <https://doi.org/10.7910/DVN/6C3JR1>

- [15] Hundman, K., et al. (2018). *Detecting Spacecraft Anomalies Using LSTMs and Nonparametric Dynamic Thresholding*. KDD. <https://github.com/khundman/telemanom>
- [16] Bagnall, A., et al. (2018). *The UEA Multivariate Time Series Classification Archive, 2018*. arXiv:1811.00075. <https://arxiv.org/abs/1811.00075>
- [17] iTrust, Singapore University of Technology and Design. *SWaT/WADI Dataset Terms of Usage*. <https://www.sutd.edu.sg/itrust/itrust-labs/datasets/terms-of-usage/>
- [18] Paparrizos, J., et al. (2024). *The Elephant in the Room: Towards a Reliable Time-Series Anomaly Detection Benchmark*. NeurIPS Datasets and Benchmarks. https://proceedings.neurips.cc/paper_files/paper/2024/hash/c3f3c690b7a99fba16d0efd35cb83b2c-Abstract-Datasets_and_Benchmarks_Track.html
- [19] Liu, J., et al. (2024). *MTAD: Tools and Benchmarks for Multivariate Time Series Anomaly Detection*. arXiv:2401.06175. <https://arxiv.org/abs/2401.06175>
- [20] Wu, R., & Keogh, E. (2021). *Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress*. IEEE TKDE. <https://arxiv.org/abs/2009.13807>
- [21] Kim, S., et al. (2022). *Towards a Rigorous Evaluation of Time-Series Anomaly Detection*. AAAI 36(7), 7194-7201. <https://doi.org/10.1609/aaai.v36i7.20680>